ĐẠI HỌC BÁCH KHOA HÀ NỘI

TRƯỜNG CÔNG NGHỆ THÔNG TIN & TRUYỀN THÔNG

*

PROJECT III

PHÂN LOẠI CHỦ ĐỀ TIN TỨC TIẾNG VIỆT SỬ DỤNG CÁC PHƯƠNG PHÁP HỌC MÁY

Giảng viên hướng dẫn: ThS. Ngô Văn Linh

Mã lớp: 732383

Sinh viên thực hiện: Chu Văn Hiếu 20194046

Hà Nội, 2023

Mục lục

Danh mục hình ảnh

Danh mục bảng biểu

A. Lời mở đầu

Ngày nay, trí tuệ nhân tạo và học máy đang dần len lỏi vào từng khía cạnh khác nhau của cuộc sống đời thường. Trí tuệ nhân tạo giúp công việc con người trở nên dễ dàng và tự động hơn.

Với mong muốn tìm hiểu và ứng dụng các mô hình Học máy đã được ở môn học, em quyết định lựa chọn đề tài "Phân loại văn bản tiếng Việt sử dụng mô hình học máy". Với đề tài này, em mong muốn thử nghiệm và đưa ra mô hình có khả năng phân loại tốt cho văn bản tiếng Việt.

Trong dự án này, em sẽ tiếp cận các phương pháp và thuật toán Học máy khác nhau. Báo cáo được chia làm các phần: Phân tích bộ dữ liệu, Các phương pháp xử lý và xây dựng mô hình, Kết quả mô hình và Kết luận cải tiến.

Em xin cảm ơn thầy Ngô Văn Linh đã hỗ trợ em trong quá trình thực hiện đề tài.

I. Đặt vấn đề

Đi cùng với sự phát triển loài người là sự bùng nổ của thông tin dữ liệu. Trong kho dữ liệu lớn đó, lượng dữ liệu văn bản chiếm một phần rất lớn, không ngừng tăng trưởng và cần được xử lý, khai thác. Điển hình như hiện nay, các trang báo điện tử ra đời nhằm cung cấp thông tin, kiến thức cho người đọc. Bên cạnh những công việc như tự động cập nhật, tổng hợp tin tức mới hàng ngày thì những trang báo này phải tổ chức, sắp xếp và phân loại những tin tức này vào đúng chủ đề của chúng. Tuy nhiên, mỗi ngày báo điện tử cung cấp hàng trăm tin tức, cho nên việc phân loại bằng tay sẽ vô cùng tốn kém và độ chính xác có thể không cao. Điều này được lý giải như sau: Văn phong tiếng Việt đa hình đa nghĩa, vô cùng phong phú, việc đọc hết một tin tức dài và phân loại nó vào đúng chủ đề là rất khó và có thể mất đến vài phút, cộng thêm việc thế giới quan của mỗi người khác nhau nên kết quả phân loại cũng sẽ khác nhau. Trong trường hợp này, kết quả phân loại sẽ mang tính chủ quan cao và chắc chắn độ chính xác cũng không cao. Tóm lại, việc giải quyết công việc phân loại tin tức một cách thủ công có hai vấn đề lớn đó là độ chính xác thấp và thời gian thực hiện lâu, trong khi đó, báo điện tử phải đáp ứng yêu cầu "nhanh" và chính xác".

Nhận thấy công việc này có thể giải quyết bằng các mô hình học máy, em sẽ quyết định xây dựng, tìm ra một mô hình có thể phân loại tin tức dựa trên nội dung của tin tức đó. Việc phân loại sử dụng các thuật toán học máy có thể cải thiện đáng kể độ chính xác, hơn thế nữa, một mô hình học máy có thể tiến hành phân loại hàng trăm

tới hàng nghìn tin tức mỗi giây, nhanh hơn rất nhiều so với các làm thủ công. Đặc biệt, con người cần hoạt động theo chu kỳ sinh học nhất định thì máy có thể hoạt động cả ngày đêm và hoàn toàn tự động. Tóm lại, việc ứng dụng học máy sẽ cho kết quả và hiệu năng vượt bậc với cách thông thường.

II. Xác định bài toán

Bài toán cần lấy bộ dữ liệu từ các chủ đề khác nhau. Sau đó em tiến hành xử lý dữ liệu thô (dạng text) để trích chọn những đặc trưng khác nhau của văn bản.

Các mô hình học máy được sử dụng: Multinomial Naive Bayes, Deep Neural Network (DNN), Long short term memory (LSTM), Gated recurrent unit (GRU), Bidirectional recurrent neural networks (BRNN), R-CNN, K-Nearest-Neighbor, Linear Classifier, Support Vector Machine (SVM), Bagging Model.

B. Tập dữ liệu bài toán

Dữ liệu huấn luyện cho bài toán được thu thập tại github:

https://github.com/duyvuleo/VNTC

Ta sẽ chia bộ dữ liệu (dataset) thành 2 phần: data **train** và data **test**. Bài toán phân lớp này sẽ chia thành 2 công việc:

- Huấn luyện:

Dùng bộ Training Text (data train) rút trích thành các bộ Features Vector đưa vào Machine Learning Algorithm từ đó thành một Predictive Model dùng để phân loại sau này, cuối cùng kết quả sẽ thu được Expect Label tên lớp cần phân loại.

- Hiện thực kết quả:

Dùng Text (data test) rút trích thành các bộ Features Vector đưa vào Predictive Model sẽ nhận được Expect Label tên lớp cần phân loại.

Bảng 1. Chi tiết tập dữ liệu

	Train	**Test**
Am nhac	900	813

Am thuc	265	400

Bat dong san	246	282
Bong da	1857	1464
Chung khoan	382	320
Cum ga	510	381
Cuoc song do day	729	405
Du hoc	682	394
Du lich	582	565
Duong vao WTO	208	191
Gia dinh	213	280
Giai tri tin hoc	825	707
Giao duc	821	707
Gioi tinh	343	268
Hackers va Virus	355	319
Hinh su	155	196
Khong gian song	134	58
Kinh doanh quoc te	571	559
Lam dep	776	735
Loi song	223	214

Mua sam	187	84
My thuat	193	144
San khau dien anh	1117	1030
San pham tin hoc moi	770	595
Tennis	588	283
The gioi tre	331	380
Thoi trang	412	302

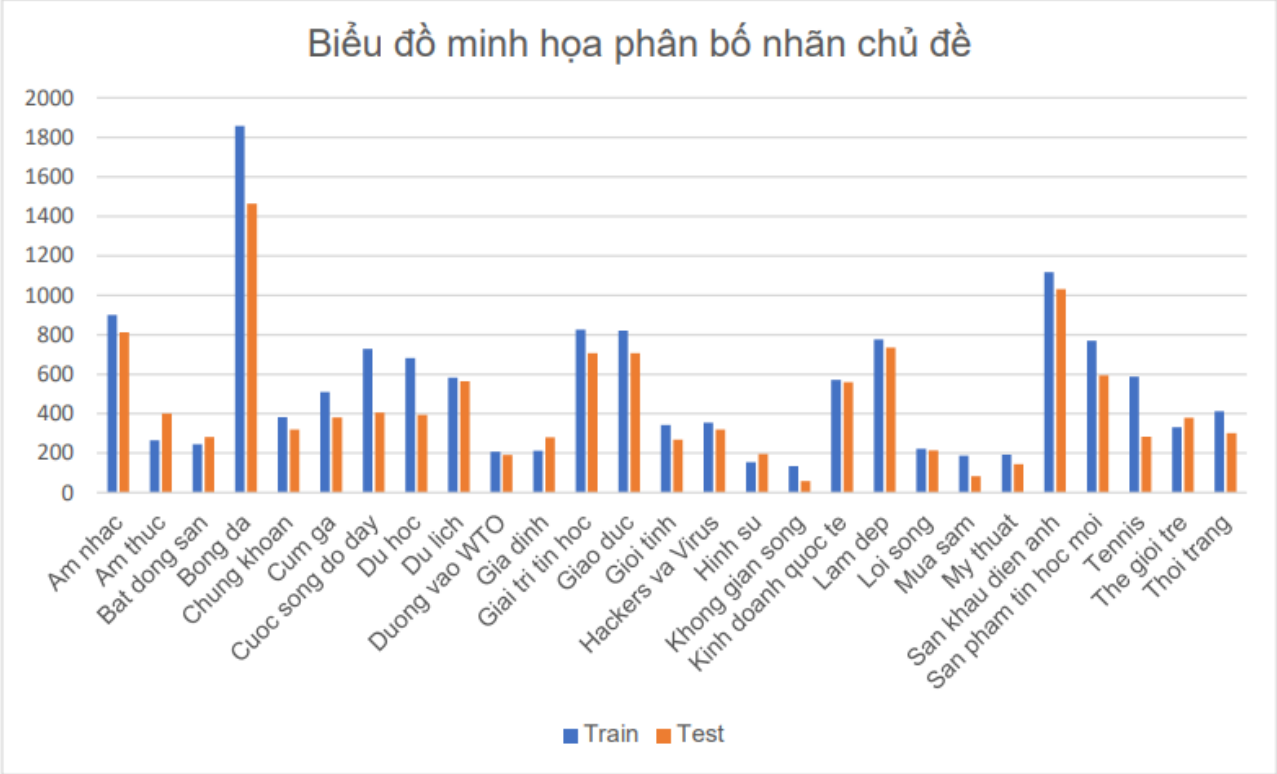

Hình 1. Biểu đồ minh họa phân bố nhãn chủ đề

C. Các phương pháp

I. Tiền xử lý dữ liệu

1. Tokenizer

Tokenization (tách từ) là một trong những bước quan trọng nhất trong quá trình tiền xử lý văn bản. Tokenization là quá trình tách một cụm từ, câu, đoạn văn, một hoặc nhiều tài liệu văn bản thành các đơn vị nhỏ hơn. Mỗi đơn vị nhỏ hơn này được gọi là Tokens.

Có thể coi tokens là các khối xây dựng của NLP và tất cả các mô hình NLP đều xử lý văn bản thô ở cấp độ các Tokens. Chúng được sử dụng để tạo từ vựng trong một kho ngữ liệu (một tập dữ liệu trong NLP). Từ vựng này sau đó được chuyển thành số (ID) và giúp chúng ta lập mô hình.

Một điểm đặc biệt trong văn bản tiếng Việt đó là đơn vị từ từ bao gồm từ đơn (một từ chỉ gồm một tiếng) và từ ghép (một từ có thể được kết hợp bởi nhiều tiếng khác nhau), ví dụ như: thủ tướng, bắt đầu,... khác với tiếng Anh và một số ngôn ngữ khác, các từ được phân cách nhau bằng khoảng trắng. Vì vậy, chúng ta cần phải tách từ và nối các từ ghép với nhau bằng dấu "_" để có thể đảm bảo ý nghĩa của từ được toàn vẹn.

Một số phương pháp phổ biến để tách từ tiếng Việt như:

1.1. Maximum match:

Ý tưởng của thuật toán này là duyệt một câu từ trái qua phải và chọn từ có nhiều tiếng nhất mà có mặt trong từ điển tiếng Việt. Nội dung thuật toán này dựa trên thuật toán đã được Chih-Hao Tsai giới thiệu năm 1996, gồm 2 dạng:

- Dạng đơn giản: Giả sử có một chuỗi các tiếng trong câu là t1, t2, ..tN. Thuật toán sẽ kiểm tra xem t1 có mặt trong từ điển hay không, sau đó kiểm tra tiếp t1-t2 có trong từ điển hay không. Tiếp tục như vậy cho đến khi tìm được từ có nhiều tiếng nhất có mặt trong từ điển, và đánh dấu từ đó. Sau đó tiếp tục quá trình trên với tất các các tiếng còn lại trong câu và trong toàn bộ văn bản. Dạng này khá đơn giản nhưng nó gặp phải rất nhiều nhập nhằng trong tiếng Việt
- Dạng phức tạp: dạng này có thể tránh được một số nhập nhằng gặp phải trong dạng đơn giản. Đầu tiên thuật toán kiểm tra xem t1 có mặt trong từ điển không, sau đó kiểm tra tiếp t1-t2 có mặt trong từ điển không. Nếu t1-t2 đều có mặt

trong từ điển thì thuật toán thực hiện chiến thuật chọn 3-từ tốt nhất. Tiêu chuẩn chọn 3 từ tốt nhất là:

- Độ dài trung bình của 3 từ là lớn nhất
- Sự chênh lệch độ dài của 3 từ là ít nhất

Ưu điểm của phương pháp: đơn giản, dễ hiểu và chạy nhanh.

Nhược điểm của phương pháp: nó không giải quyết được 2 vấn đề quan trọng nhất của bài toán phân đoạn từ tiếng Việt: thuật toán gặp phải nhiều nhập nhằng, hơn nữa nó hoàn toàn không có chiến lược gì với những từ chưa biết.

1.2. Maximum entropy:

Ý tưởng chính của Maximum Entropy là "ngoài việc thõa mãn một số ràng buộc nào đó thì mô hình càng đồng đều càng tốt". Ta xem xét bài toán toán phân lớp gồm có 4 lớp. Ràng buộc duy nhất mà chúng ta biết là trung bình 40% các tài liệu chứa từ "professor" thì nằm trong lớp faculty. Trực quan cho thấy nếu có một tài liệu chứa từ "professor" chúng ta có thể nói có 40% khả năng tài liệu này thuộc lớp faculty, và 20% khả năng cho các khả năng còn lại (thuộc một trong 3 lớp còn lại). Mặc dù maximum entropy có thể được dùng để ước lượng bất kì một phân phối xác suất nào, chúng ta cần tập trung vào việc học ra phân phối điều kiện của chuỗi nhãn tương ứng với chuỗi (xâu) đầu vào cho trước

Trong maximum entropy, người ta dùng dữ liệu huấn luyện để xác định các ràng buộc trên phân phối điều kiện. Mỗi ràng buộc thể hiện một đặc trưng nào đó của dữ liệu huấn luyện. Maximum Entropy cho phép chúng ta giới hạn các phân phối mô hình lý thuyết gần giống nhất các giá trị kỳ vọng cho các đặc trưng này trong dữ liệu huấn luyện D. Người ta mô hình hóa xác suất P(o | s) (o là chuỗi đầu vào và s là chuỗi nhãn đầu ra):

$$P(o \mid s) = \frac{1}{Z(o)} \exp\left(\sum_i \lambda_i f_i(o,s)\right)$$

Trong đó:

- $P(o \mid s)$ là một đặc trưng
- λ_i là một tham số cần phải ước lượng
- $Z(o)$ là thừa số chuẩn hóa nhằm đảm bảo tính đúng đắn của định nghĩa

xác suất

1.3. CRF

CRF là một khung để xây dựng các mô hình xác suất giúp phân đoạn và gán nhãn dữ liệu tuần tự hay các thực thể định danh. Các thực thể đó biểu thị cho các từ trong câu đại diện cho các đối tượng như tên người, tổ chức, địa điểm,…CRF là thuật toán xác suất có điều kiện $P(y|x)$ với xác suất của vector đầu ra y của một biến ngẫu nhiên được cung cấp bởi một vector đặc trưng x.

Để dự đoán chuỗi thích hợp thì ta phải tối đa hóa xác suất có điều kiện và ta lấy chuỗi với xác suất lớn nhất:

$$\hat{y} = argmax_y P(y|x)$$

Một cách tổng quát, mô hình CRF sử dụng cho việc gán nhãn thực thể, giải quyết nhược điểm sai lệch nhãn do các nhãn độc lập với nhau của mô hình Markov ẩn. CRF trước tiên xác định các hàm tính năng cần thiết, khởi tạo trọng số lambda cho các giá trị ngẫu nhiên và sau đó áp dụng phương pháp gradient descent lặp đi lặp lại cho đến khi các giá trị tham số hội tụ.

Trong CRF, dữ liệu đầu vào là tuần tự và chúng ta phải dựa vào ngữ cảnh trước đó để đưa ra dự đoán về một điểm dữ liệu

Hiện nay, có khá nhiều thư viện mã nguồn mở của bài toán này. Với ngôn ngữ Python, có 2 thư viện phổ biến là *underthesea* hoặc *pyvi*.

2. Loại bỏ “stop word”

Bên cạnh các xử lý trên, chúng ta còn phải cần quan tâm đến 1 xử lý khác nữa. Đó là việc loại bỏ stop word. Bước xử lý này góp phần giúp giảm số lượng từ, loại bỏ các từ không mang ý nghĩa, tăng tốc độ học và xử lý, và nâng cao kết quả của mô hình.

Stopwords là những từ xuất hiện nhiều trong ngôn ngữ tự nhiên, tuy nhiên lại không mang nhiều ý nghĩa. Ở tiếng việt Stopwords là các từ nối (của, là, có, được, những…). Danh sách stopword phải được xây dựng từ bộ dữ liệu văn bản lớn, của toàn bộ bộ dữ liệu. Để loại bỏ các stopword, ta sẽ làm theo phương pháp dựa trên tần suất xuất hiện của từ. Ta tiến hành đếm số lần xuất hiện của từng từ trong dataset.

Dữ liệu về các tần suất xuất hiện các từ sẽ được lưu vào 1 cấu trúc dictionary với key là chính từ ấy, value là số lần xuất hiện. Dữ liệu sau đó được sắp xếp theo chiều giảm dần value, tức là các từ có tần suất xuất hiện càng cao thì xếp trên đầu và nhiều khả năng là các stopword. Ta lấy top 100 (có thể lấy nhiều hoặc ít hơn) của dữ liệu tần suất vừa thu được, sẽ là các từ stopword cần loại bỏ.

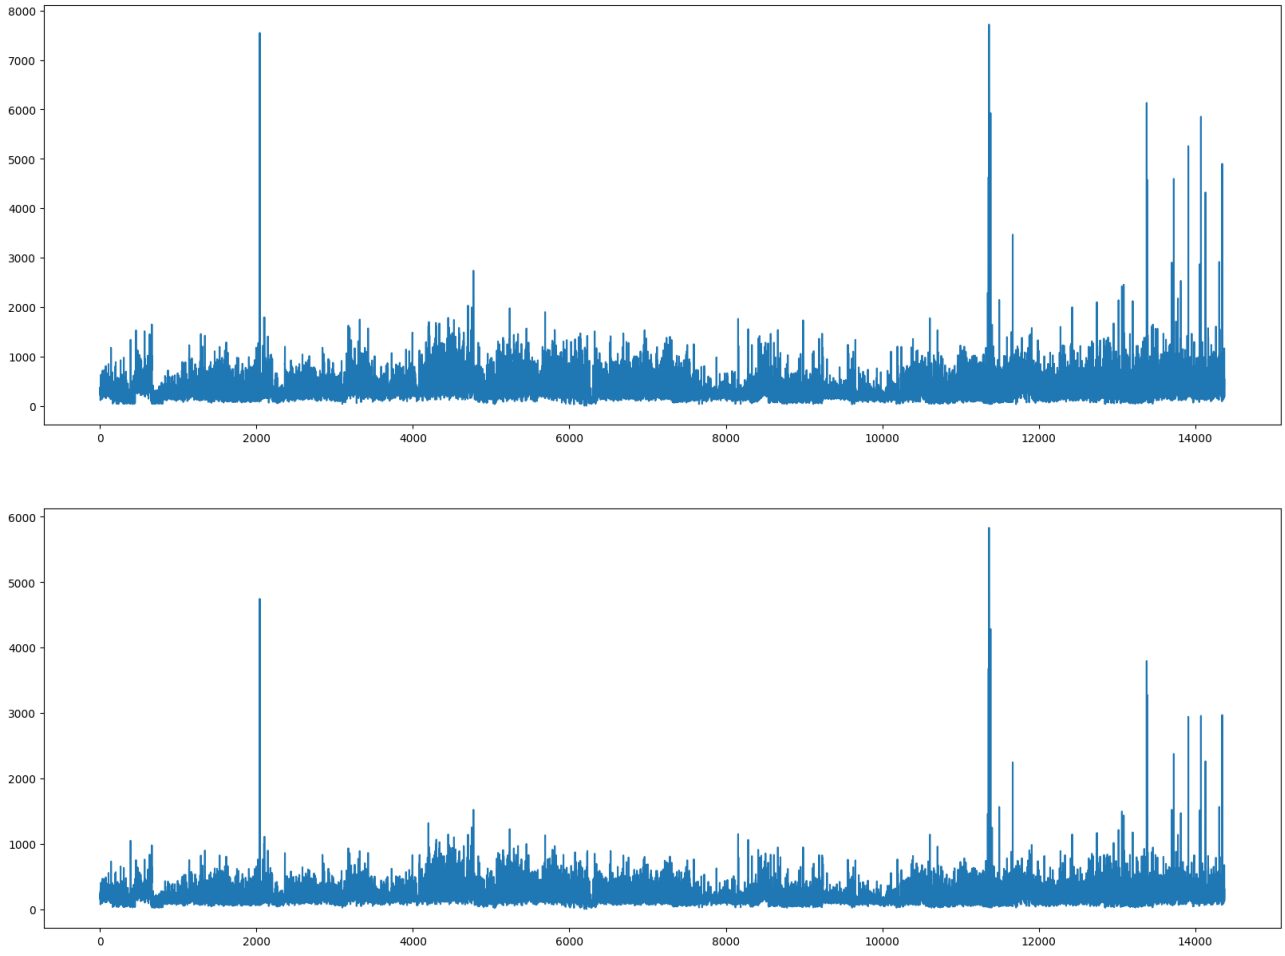

Hình 2. Phân bố độ dài văn bản sau khi loại bỏ stop word

II. Trích chọn đặc trưng

1. TF-IDF

Mục đích: chuyển hóa văn bản đã tách từ thành các vector đặc trưng.

Sử dụng TF-IDF (term frequency – inverse document frequency) là trọng số của một từ trong văn bản thu được qua thống kê thể hiện mức độ quan trọng của từ này trong

một văn bản, mà bản thân văn bản đang xét nằm trong một tập hợp các văn bản. Trọng số này được sử dụng để đánh giá tầm quan trọng của một từ trong một văn bản. Giá trị cao thể hiện độ quan trọng cao (phụ thuộc vào số lần từ xuất hiện trong văn bản), nhưng bù lại bởi tần suất của từ đó trong tập dữ liệu (có những từ như: và, nhưng,… mặc dù xuất hiện nhiều trong văn bản, nhưng lại xuất hiện nhiều trong tập dữ liệu nên mức độ quan trọng sẽ được giảm đi).

Cách tính TF-IDF

1.1. TF:

Dùng để ước lượng tần suất xuất hiện của từ trong văn bản. Tuy nhiên với mỗi văn bản thì có độ dài khác nhau, vì thế số lần xuất hiện của từ có thể nhiều hơn. Vì vậy số lần xuất hiện của từ sẽ được chia độ dài của văn bản (tổng số từ trong văn bản đó)

Công thức:

TF(t, d) = (số lần từ t xuất hiện trong văn bản d) / (tổng số từ trong văn bản d)

1.2. IDF

Dùng để đo mức độ quan trọng của một từ trong một số lượng lớn các văn bản. Ví dụ, một số từ nối: và, nhưng, ở,… xuất hiện nhiều trong tất cả các văn bản nhưng thường không có ý nghĩa quan trọng. Vì vậy ta cần giảm đi mức độ quan trọng của những từ đó bằng cách sử dụng IDF

IDF(t, D) = log(Tổng số văn bản trong tập mẫu D/ Số văn bản có chứa từ t)

Giá trị của TF-IDF = TF(t, d) * IDF(t, D)

Trong đó: t là một từ riêng lẻ

d là một văn bản

D là một tập văn bản

1.3. Triển khai thuật toán tính TF-IDF

B1: Tiền xử lý

```
#preprocessing the text data
sentences = []
word_set = []

for sent in text:
  x = [i.lower() for  i in sent if i.isalpha()]
  sentences.append(x)
  for word in x:
    if word not in word_set:
      word_set.append(word)
word_set = set(word_set)
total_documents = len(sentences)
index_dict = {}
i = 0
for word in word_set:
  index_dict[word] = i
  i += 1
```

Hình 3. Xây dựng tập từ điển từ tập dữ liệu

Chú thích:

- ➢ sentences là tập các bài báo (D)
- ➢ word_set là tập các từ xuất hiện trong bài báo d (các từ trong word_set là khác nhau)
- ➢ text: mảng chứa tất cả các văn bản

B2: Tính số văn bản mà mỗi từ trong word_set xuất hiện

```
def count_dict(sentences):
  word_count = {}
  for word in word_set:
    word_count[word] = 0
    for sent in sentences:
      if word in sent:
        word_count[word] += 1
  return word_count
word_count = count_dict(sentences)
```

Hình 4. Hàm tính số lượng văn bản mà một từ 'word' có trong

Chú thích: word_count là một set với key là một từ riêng lẻ value là số văn bản mà

từ đó xuất hiện

B3: Tính tần suất xuất hiện của một từ word trong một văn bản document (TF)

```
def termfreq(document, word):
  N = len(document)
  occurance = len([token for token in document if token == word])
  return occurance/N
```

Hình 5. Hàm tính tần số xuất hiện của một từ trong văn bản

B4: Tính IDF

```
def inverse_doc_freq(word):
  try:
    word_occurance = word_count[word] + 1
  except:
    word_occurance = 1
  return np.log(total_documents/word_occurance)
```

Hình 6. Hàm tính IDF cho một từ

B5: Tính TF-IDF cho mỗi văn bản d

```
[20] def tf_idf(sentence):
       tf_idf_vec = np.zeros((len(word_set),))
       for word in sentence:
         tf = termfreq(sentence,word)
         idf = inverse_doc_freq(word)
         value = tf*idf
         tf_idf_vec[index_dict[word]] = value
       return tf_idf_vec
```

Hình 7. Hàm tính TF-IDF cho văn bản

Kết quả: Thu được biểu diễn dạng vector của văn bản d

```
vectors = [];
for sent in sentences:
  vec = tf_idf(sent)
  vectors.append(vec)
print(vectors[0])
```

```
[0.         0.         0.         0.         0.         0.
 0.         0.         0.         0.         0.         0.42374168
 0.         0.         0.         0.         0.         0.
 0.         0.         0.         0.         0.         0.
 0.         0.         0.         0.         0.         0.
 0.         0.         0.         0.         0.         0.
 0.4540656  0.         0.         0.         0.         0.
 0.         0.         0.         0.         0.         0.
 0.87165326 0.        ]
```

Hình 8. Biểu diễn dạng vector của một văn bản ngắn

Ngoài cách trên, em sử dụng hàm TfidfVectorizer() do thư viện sklearn cung cấp để tính nhanh TF-IDF của tập văn bản

```
from sklearn.feature_extraction.text import TfidfVectorizer, CountVectorizer
tfidf_vect = TfidfVectorizer(ngram_range=(1, 2), max_df=0.5, analyzer='word', max_features=30000)
tfidf_vect.fit(X_data) # learn vocabulary and idf from training set
```

Hình 9. Source code tính TF-IDF cho tập dữ liệu văn bản

- ➢ Tham số ngram_range=(min_n, max_n): giá trị nhỏ nhất và lớn nhất của số lượng từ tạo nên đặc trưng.
- ➢ Tham số max_df: một số thực là giá trị lớn nhất của DF, đối với những từ có DF lớn hơn giá trị max_df thì sẽ lấy giá trị là max_df
- ➢ Tham số analyzer: nhậm một trong 3 giá trị {'word', 'char', 'char_wb'}, tương ứng với việc coi những đặc trưng (các từ trong từ điển) một từ, ký tự hay n từ
- ➢ Tham số max_feature: số lượng đặc trưng tối đa

1.4. Nhược điểm của TF-IDF

Sau khi thực hiện TF-IDF, chúng ta dễ dàng nhận thấy rằng, ma trận mà chúng ta thu được có kích thước rất lớn, và việc xử lý tính toán với ma trận này đòi hỏi thời gian và bộ nhớ khá tốn kém. Giả sử, chúng ta có 100.000 văn bản và bộ từ điển bao gồm 50000 từ, khi đó ma trận mà chúng ta thu được sẽ có kích thước là *100000* *

50000. Giả sử mỗi phần tử được lưu dưới dạng float32 - 4 byte, bộ nhớ mà chúng ta cần sử dụng là:

$$100000 \times 50000 \times 4 = 20000000000 \text{ byte}$$

tức là chúng ta tốn tầm 18.63GB bộ nhớ, khó có thể lưu hết vào RAM để thực hiện tính toán.

2. SVD

Trong thực tế, với số lượng văn bản khổng lồ và từ điển lên đến hàng trăm nghìn từ, bộ nhớ mà chúng ta sử dụng còn tốn kém hơn rất nhiều. Để xử lý vấn đề này, chúng ta sẽ sử dụng thuật toán SVD (**singular value decomposition**) nhằm mục đích giảm chiều dữ liệu của ma trận mà chúng ta thu được sau khi tính TF-IDF, với SVD ta sẽ loại bỏ được những "stop word" không mang nhiều ý nghĩa mà vẫn giữ nguyên được các thuộc tính quan trọng của ma trận gốc ban đầu.

2.1. Cơ sở toán học

Một ma trận A_{mxn} bất kỳ đều có thể phân tích thành dạng:

$$\mathbf{A}_{m \times n} = \mathbf{U}_{m \times m} \mathbf{\Sigma}_{m \times n} (\mathbf{V}_{n \times n})^T$$

Trong đó:

U,V: là các ma trận trực giao,

Σ: là ma trận *đường chéo* với các phần tử trên đường chéo $\sigma 1 \geq \sigma 2 \geq \cdots \geq \sigma r \geq 0 = 0 = \cdots = 0$

Mặc dù, Σ không phải ma trận vuông, ta vẫn có thể coi nó là ma trận chéo nếu các thành phần khác không của nó chỉ nằm ở vị trí *đường chéo*, tức tại các vị trí có chỉ số hàng và chỉ số cột là như nhau.

Số lượng các phần tử khác 0 trong Σ chính là rank của ma trận A.

- Compact SVD

A có thể được biểu diễn bằng tổng của các ma trận có rank bằng 1

$$\mathbf{A} = \sigma_1 \mathbf{u}_1 \mathbf{v}_1^T + \sigma_2 \mathbf{u}_2 \mathbf{v}_2^2 + \cdots + \sigma_r \mathbf{u}_r \mathbf{v}_r^T$$

Trong cách biểu diễn này, ma trận A chỉ phụ thuộc vào r cột đầu tiên của U,V và r giá trị khác 0 trên đường chéo của ma trận Σ. Vì vậy ta có một cách phân tích gọn hơn và gọi là *compact SVD*:

$$\mathbf{A} = \mathbf{U}_r \Sigma_r (\mathbf{V}_r)^T$$

Với U_r,V_r lần lượt là ma trận được tạo bởi r cột đầu tiên của U và V.

Σ_r là ma trận con được tạo bởi r hàng đầu tiên và r cột đầu tiên của Σ.

- Truncated SVD

Trong ma trận Σ, các giá trị trên đường chéo (σ1, σ2 ⋯, σr) là không âm và giảm dần. Khi đó có thể xấp xỉ ma trận A bằng tổng của k < r ma trận có rank 1

$$\mathbf{A} \approx \mathbf{A}_k = \mathbf{U}_k \Sigma_k (\mathbf{V}_k)^T = \sigma_1 \mathbf{u}_1 \mathbf{v}_1^T + \sigma_2 \mathbf{u}_2 \mathbf{v}_2^2 + \cdots + \sigma_k \mathbf{u}_k \mathbf{v} k^T$$

Sai số do cách xấp xỉ trên là căn bậc hai của tổng bình phương của các singular values mà ta đã bỏ qua ở phần cuối của Σ. Ở đây sai số được định nghĩa là Frobenius norm của hiệu hai ma trận:

$$||\mathbf{A} - \mathbf{A}_k||_F^2 = \sum_{i=k+1}^{r} \sigma_i^2$$

Có thể kết luận rằng: sai số do xấp xỉ càng nhỏ nếu phần singular values bị ***truncated*** có giá trị càng nhỏ so với phần singular values được giữ lại.

Tổng quát: nếu ta muốn giữ lại ít nhất a% lương thông tin trong A, trước hết ta cần chọn k là số nhỏ nhất sao cho:

$$\frac{\sum_{i=1}^{k} \sigma_i^2}{\sum_{j=1}^{r} \sigma_j^2} \geq$$ a

Ưu điểm: Giảm chi phí tính toán, có lợi về lưu trữ nếu k << m,n. Để lưu ma trận với Truncated SVD, ta sẽ lưu các ma trận Uk, Σk,Vk. Khi đó tổng số phần tử phải lưu là k(m+n+1), với chú ý rằng ta chỉ cần lưu các giá trị trên đường chéo của Σ_k

Giả sử mỗi phần tử được lưu bởi một số thực 4 byte, thì số byte cần lưu trữ là 4k(m+n+1). Nếu so giá trị này với ảnh gốc có kích thước mn mỗi giá trị là 1 số nguyên 1 byte, tỉ lệ nén là:

$$\frac{4k(m+n+1)}{mn}$$

Tỉ lệ này nhỏ hơn 1

2.2. Áp dụng cho bài toán giảm chiều dữ liệu:

Áp dụng cho ma trận TF-IDF của dữ liệu, m cột của U đại diện cho một cơ sở trực giao cho không gian vectơ kéo dài bởi các hàng của A. Với giả thiết, A là ma trận TF-IDF, các cột của U sẽ biểu thị một cơ sở trực giao cho không gian văn bản tương quan. Tương tự, n cột của V đại diện cho một cơ sở trực giao cho không gian vectơ mở rộng bởi các cột của A. Vì các cột của ma trận TF-IDF tương ứng với các bài báo, nên V sẽ cung cấp một cơ sở trực giao cho không gian từ trong từ điển.

Thư viện Sklearn cung cấp hàm TruncatedSVD() để tính truncatedSVD cho ma trận văn bản được tạo ra từ phương pháp TF-IDF.

```
svd = TruncatedSVD(n_components=300, random_state=42)
svd.fit(X_data_tfidf)
```

Hình 10. Source code giảm chiều vector TF-IDF bằng hàm TruncatedSVD

- ➢ Tham số n_components là kích thước mong muốn của dữ liệu đầu ra
- ➢ Tham số random_states là số lượng kết quả có thể tái sinh qua nhiều lần gọi hàm

III. Xây dựng mô hình

1. Naive-Bayes

1.1. Định lý Bayes

Định lý Bayes cho phép tính xác suất xảy ra của một sự kiện ngẫu nhiên A khi biết sự kiện liên quan B đã xảy ra. Xác suất này được ký hiệu là $P(A|B)$, và đọc là "xác suất của A khi có B". Đại lượng này được gọi xác suất có điều kiện hay xác suất hậu nghiệm vì nó được rút ra từ giá trị được cho của B hoặc phụ thuộc vào giá trị đó.

Theo định lý Bayes, xác suất xảy ra A khi biết B sẽ phụ thuộc vào 3 yếu tố:

- Xác suất xảy ra A của riêng nó, không liên quan đến B. Kí hiệu là P(A). Đây được gọi là xác suất biên duyên hay xác suất tiên nghiệm, nó là "tiên nghiệm" theo nghĩa rằng nó không quan tâm đến bất kỳ thông tin nào về B.
- Xác suất xảy ra B của riêng nó, không liên quan đến A. Kí hiệu là P(B). Đại lượng này còn gọi là hằng số chuẩn hóa (normalization constant), vì nó luôn giống nhau, không phụ thuộc vào sự kiện A đang muốn biết.
- Xác suất xảy ra B khi biết A xảy ra. Kí hiệu là P(B|A) - "xác suất của B nếu có A". Đại lượng này gọi là khả năng (likelihood) xảy ra B khi biết A đã xảy ra.

Công thức

$$P(A|B) = \frac{P(B|A)P(A)}{P(B)}$$

Công thức chỉ ra xác suất của A xảy ra nếu B cũng xảy ra, ta viết là $P(A|B)$. Và nếu ta biết xác suất của B xảy ra khi biết A, ta viết là $P(B|A)$ cũng như xác suất độc lập của A và B.

- P(A|B) là "xác suất của A khi biết B"
- P(A) là "xác suất xảy ra của A"
- P(B|A) là "xác suất của B khi biết A"
- P(B) là "xác suất xảy ra của B"

Như vậy, định lý Bayes sẽ giúp chúng ta tính toán được khả năng xảy ra của một giả thuyết bằng việc thu thập những bằng chứng nhất quán hay không nhất quán với một giả thuyết nào đó. Khi các bằng chứng được thu thập, mức độ tin tưởng đối với một giả thuyết sẽ thay đổi. Khi có đủ bằng chứng, mức độ tin tưởng này thường trở nên rất cao hay cực thấp, và xác xuất khả năng xảy ra của giả thuyết sẽ thay đổi nếu các

bằng chứng liên quan đến nó thay đổi.

1.2. Mô hình phân lớp Naive Bayes

Naive Bayes là một thuật toán phân loại cho các vấn đề phân loại nhị phân (hai lớp) và đa lớp. Kỹ thuật này dễ hiểu nhất khi được mô tả bằng các giá trị đầu vào nhị phân hoặc phân loại. Nó là thuật toán được mô hình hoá dựa trên định lý Bayes trong xác suất thống kê.

Xét bài toán có $X = (x_1, x_2, \dots, x_d)$ là vector các đặc trưng và tập classes C (mỗi class ký hiệu là c). Khi đó đẳng thức Bayes trở thành:

$$p(c|X) = p(c|x1, x2, \dots, xd) = \frac{p(x1|c)\, p(x2|c) \dots p(x2|c)}{p(x1)p(x2) \dots p(xd)}. p(c)$$

(Tức là tính xác suất để đầu ra là class c, biết đầu vào là X)

Từ đó, có thể xác định class của điểm dữ liệu X bằng cách chọn ra class có xác suất cao nhất trong C:

$$c = arg \max_{c \in C} p(c|X) \qquad (c \in C)$$

Biểu thức này thường khó được tính trực tiếp. Thay vào đó, quy tắc Bayes thường được sử dụng như sau:

$$c = \arg max\ p(c|X) = arg\ max \frac{p(X|c)}{p(X)}. p(c) = \arg max\ p(X|c)p(c)$$

(Do mẫu số $p(X)$ không phụ thuộc vào c)

Trong đó:

- $p(c)$ có thể được hiểu là xác suất để một điểm rơi vào class c
- $p(x|c)$ là phân phối của những điểm dữ liệu trong class c, nó khá khó tính toán bởi vì X là một biến ngẫu nhiên nhiều chiều và đòi hỏi sử dụng rất nhiều dữ liệu training mới có thể xây dựng được phân phối đó. Để giúp cho việc tính toán trở nên dễ dàng hơn người ta hay giả sử một cách đơn giản nhất là các thành phần của biến ngẫu nhiên X là **độc lập với nhau**, nếu biết c:

$$p(X|c) = p(x1, x2, \dots, xd|c) = \prod_{i=1}^{d} p(x_i|c)$$

Trên thực tế, việc các thành phần độc lập với nhau ít khi xảy ra. Tuy nhiên, giả thiết "ngây thơ" này có thể mang lại kết quả tốt bất ngờ. Giả thiết về sự độc lập của các chiều dữ liệu này được gọi là **Naive Bayes**. Cách xác định class của dữ liệu

dựa trên giả thiết này có tên là **Naive Bayes Classifier (NBC)**.

Bởi vì "ngây thơ" nên phương pháp này có tốc độ training và test đều rất nhanh, giúp cho các bài toán được giải quyết nhanh và dễ dàng hơn.

Ở bước **training**, các phân phối $p(c)$ và $p(xi|c)$, i=1,…, d sẽ được xác định dựa vào training data, bằng phương pháp Maximum Likelihood Estimation (MLE) hoặc Maximum A Posteriori (MAP), chủ yếu là dùng MLE.

Ở bước **test**, với một dữ liệu mới X nào đó, class của nó sẽ được xác đinh bởi:

$$c = arg \max p(c) \prod_{i=1}^{d} \quad p(x_i|c) \; (c \in C)$$

Khi d lớn và các xác suất nhỏ, biểu thức ở vế phải của biểu thức này sẽ là một số rất nhỏ, khi tính toán có thể gặp sai số. Để giải quyết việc này, nó thường được viết lại dưới dạng tương đương bằng cách lấy log của vế phải

$$c = \underset{c \in C}{arg \max} \; p(c) = \log(p(c)) + \sum_{i=1}^{d} \log (p(x_i|c))$$

Do log là một hàm đồng biến trên tập các số dương nên việc này không ảnh hưởng tới kết quả.

Mặc dù giả thiết mà Naive Bayes Classifiers sử dụng là quá phi thực tế, chúng vẫn hoạt động khá hiệu quả trong nhiều bài toán thực tế, đặc biệt là trong các bài toán phân loại văn bản, ví dụ như lọc tin nhắn rác hay lọc email spam.

Thuật toán này là một thuật toán mạnh mẽ được ứng dụng trong các bài toán:

- Dự đoán với thời gian thực
- Phân loại Văn bản/ Lọc thư rác/ Phân tích tình cảm
- Hệ thống Gợi ý (Recommendation)

Naive Bayes chia thành một số kiểu mô hình cơ bản: Multinomial Naive Bayes, Bernoulli Naive Bayes, Gaussian Naive Bayes,… Trong đó, mô hình **Multinomial Naive Bayes** chủ yếu được sử dụng trong bài toán phân loại văn bản.

Ưu điểm

- Dễ dàng và nhanh chóng khi dự đoán lớp của tập dữ liệu thử nghiệm. Nó cũng hoạt động hiệu quả đối với dự đoán nhiều lớp
- Khi giả định giữ độc lập, bộ phân loại Naive Bayes hoạt động hiệu quả hơn

so với những thuật toán khác vì cần ít dữ liệu đào tạo hơn.
- Nó hoạt động tốt khi có sự chệnh lệch số lượng giữa các lớp phân loại.

Nhược điểm

- Nếu biến phân loại có một danh mục (trong tập dữ liệu thử nghiệm), không được quan sát trong tập dữ liệu huấn luyện, thì mô hình sẽ chỉ định xác suất 0 (không) và làm cho dự đoán sẽ không còn chính xác. Trường hợp này còn được gọi là **"Tần số không"**. Để giải quyết vấn đề này, chúng ta có thể sử dụng kỹ thuật Smooth. Một trong những kỹ thuật làm mịn đơn giản nhất được gọi là ước lượng Laplace (sẽ được phân tích kỹ hơn ở phần sau – 1.3).
- Mặt khác, Naive Bayes cũng được biết đến như một công cụ ước lượng tồi, vì vậy kết quả xác suất từ dự đoán_proba không được coi trọng quá.
- Một hạn chế khác của Naive Bayes là giả định rằng các yếu tố dự đoán độc lập. Tuy nhiên trong thực tế hầu như không thể có được một tập hợp các yếu tố dự đoán hoàn toàn độc lập với nhau.

1.3. Mô hình Multinomial Naive Bayes

Mô hình Multinomial Naive Bayes chủ yếu được sử dụng trong phân loại văn bản, nghĩa là một tài liệu cụ thể thuộc về danh mục nào như Thể thao, Chính trị, giáo dục, v.v.

Giả sử ta có văn bản X được biểu diễn thành vector và tập classes C (chứa các class c)

$$X = (x_1, x_2, \dots, x_d)\ (x_i \geq 0)$$

Lúc này, mỗi văn bản được biểu diễn bởi một vector có độ dài d - số từ trong từ điển. Giá trị của thành phần thứ i trong mỗi vector chính là số lần từ thứ i xuất hiện trong văn bản đó.

Khi đó, $p(xi|c)$ tỉ lệ với tần suất từ thứ i (hay feature thứ i cho trường hợp tổng quát) xuất hiện trong các văn bản của class c. Công thức tính giá trị này:

$$\lambda ci = p(xi|c) = \frac{Nci}{Nc}$$

Trong đó:

- Nci là tổng số lần từ x_i xuất hiện trong các văn bản của class c, nó được tính là tổng của tất cả các thành phần thứ i của các feature vectors ứng với class c.
- Nc là tổng số từ (kể cả lặp) xuất hiện trong class c (Tức là tổng độ dài của toàn bộ các văn bản thuộc vào class c). Có thể suy ra

$$Nc = \sum_{i=1}^{d} Nci \quad \Rightarrow \sum_{i=1}^{d} \lambda_{ci} = 1$$

Hạn chế: Cách tính này có một hạn chế là nếu như có một từ mới x_k chưa bao giờ xuất hiện trong class c thì $N_{ck} = 0$, dẫn đến $p(x_k \mid C) = 0 \Rightarrow$ Kết quả sẽ không chính xác

Giải quyết: dùng ***Laplace smoothing***, tức là cộng vào cả tử và mẫu giá trị luôn khác 0:

$$\lambda_{ci} = p'(xi|C) = \frac{Nci + \alpha}{Nc + d\alpha}$$

Trong đó α là một số dương, thường bằng 1, để tránh tử số bị bằng 0.

Mẫu số được cộng với dα để đảm bảo tổng xác suất sau bằng 1

$$\sum_{i=1}^{d} \lambda'_{Ci} = 1$$

Vấn đề: Cần tìm α để $\lambda'_{Ci} - \lambda_{Ci}$ min. Như vậy thì sai số mới tối thiểu và accuracy (độ chính xác) có thể lớn nhất.

Ta sẽ dùng vòng lặp for cho các giá trị α để tìm α tốt nhất

```
[18] # Thử nghiệm với Naive Bayes
     # bộ tham số alpha
     alphas = [0.000001, 0.00001, 0.0001, 0.01, 0.1, 0.5, 1.0, 2.0, 10.0]
     # Mảng lưu kết quả thí nghiệm
     val_acc = []
     val_f1 = []
     train_acc = []
     train_f1 = []

     X_train, X_val, y_train, y_val = model_selection.train_test_split(X_data_tfidf, y_data, test_size=0.1, random_state=42)

     for alpha in alphas:
       model=nb.MultinomialNB(alpha=alpha, fit_prior=True)

       model.fit(X_train, y_train)

       train_predictions = model.predict(X_train)
       val_predictions = model.predict(X_val)
       val_acc.append(accuracy_score(val_predictions, y_val))
       train_acc.append(accuracy_score(train_predictions, y_train))
       val_f1.append(f1_score(val_predictions, y_val, average='weighted'))
       train_f1.append(f1_score(train_predictions, y_train, average='weighted'))
```

Hình 11. Source code tìm α tốt nhất để accuracy lớn nhất

1.4. Triển khai mô hình Multinomial Naive Bayes

```
[ ] # Train với Naive Bayes
    X_train, X_val, y_train, y_val = model_selection.train_test_split(X_data_tfidf, y_data, test_size=0.1, random_state=42)
    model=nb.MultinomialNB(alpha=0.01, fit_prior=True)

    model.fit(X_train, y_train)

    val_predictions = model.predict(X_val)
    test_predictions = model.predict(X_test_tfidf)

    print("Validation accuracy: ", sklearn.metrics.accuracy_score(val_predictions, y_val))
    print("Test accuracy: ", sklearn.metrics.accuracy_score(test_predictions, y_test))

    Validation accuracy:  0.8866481223922114
    Test accuracy:  0.8916859887379928
```

Hình 12. Source code triển khai mô hình Multinomial Naive Bayes

2. Mạng nơ-ron nhân tạo

2.1. Mạng nơ-ron nhân tạo (Neural Network) là gì?

Mạng nơ-ron nhân tạo là một chuỗi những thuật toán được đưa ra để tìm kiếm các mối quan hệ cơ bản trong tập hợp các dữ liệu. Thông qua việc bắt bước cách thức hoạt động từ não bộ con người. Nói cách khác, mạng nơ ron nhân tạo được xem là hệ thống tính toán lấy cảm hứng từ sự hoạt động của các nơ-ron trong hệ thần kinh.

2.2. *Hoạt động của các nơ-ron*

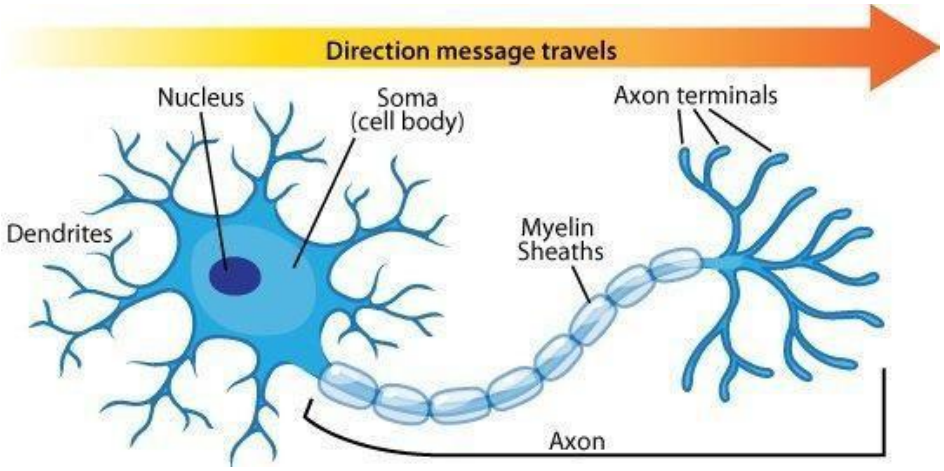

Hình 13. Mô hình giải phẫu thần kinh nơ-ron

Nơ-ron là đơn vị cơ bản cấu tạo hệ thống thần kinh và là một phần quan trọng nhất của não. Não chúng ta gồm khoảng 10 triệu nơ-ron và mỗi nơ-ron liên kết với 10.000 nơ-ron khác.

Ở mỗi nơ-ron có phần thân (soma) chứa nhân, các tín hiệu đầu vào qua sợi nhánh (dendrites) và các tín hiệu đầu ra qua sợi trục (axon) kết nối với các nơ-ron khác. Hiểu đơn giản mỗi nơ-ron nhận dữ liệu đầu vào qua sợi nhánh và truyền dữ liệu đầu ra qua sợi trục, đến các sợi nhánh của các nơ-ron khác.

Mỗi nơ-ron nhận xung điện từ các nơ-ron khác qua sợi nhánh. Nếu các xung điện này đủ lớn để kích hoạt nơ-ron, thì tín hiệu này đi qua sợi trục đến các sợi nhánh của các nơ-ron khác.

Tuy nhiên Mạng nơ-ron nhân tạo chỉ là lấy cảm hứng từ não bộ và cách nó hoạt động, chứ không phải bắt chước toàn bộ các chức năng của nó. Việc chính của chúng ta là dùng mô hình đấy đi giải quyết các bài toán chúng ta cần.

2.3. *Mô hình Mạng nơ-ron nhân tạo tổng quát*

Mạng Nơ-ron nhân tạo là sự kết hợp của những tầng perceptron hay còn gọi là perceptron đa tầng. Và mỗi một mạng nơ-ron nhân tạo thường bao gồm 3 kiểu tầng là:

- Tầng vào(input layer): Tầng này nằm bên trái cùng của mạng, thể hiện cho các đầu vào của mạng.

- Tầng ra (output layer): Là tầng bên phải cùng và nó thể hiện cho những đầu ra của mạng.
- Tầng ẩn (hidden layer): Tầng này nằm giữa tầng vào và tầng ra nó thể hiện cho quá trình suy luận logic của mạng.

Mỗi mô hình luôn có một tầng vào, một tầng ra, có thể có hoặc không các tầng ẩn. Tổng số tầng trong mô hình được quy ước là số tầng - 1 (Không tính tầng vào).

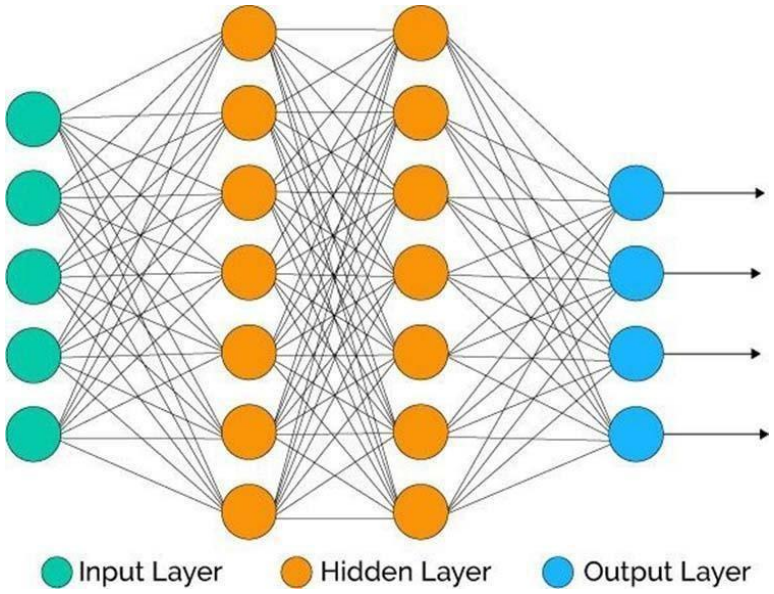

Hình 14. Kiến trúc mạng nơ-ron nhân tạo

Mỗi node trong tầng ẩn và tầng ra:

- Liên kết với tất cả các node ở tầng trước đó với các hệ số trọng số(weight) riêng.
- Mỗi node có một hệ số sai khác(bias) riêng.
- Diễn ra hai bước: tính tổng tuyến tính(linear) và áp dụng hàm kích hoạt (activation function).

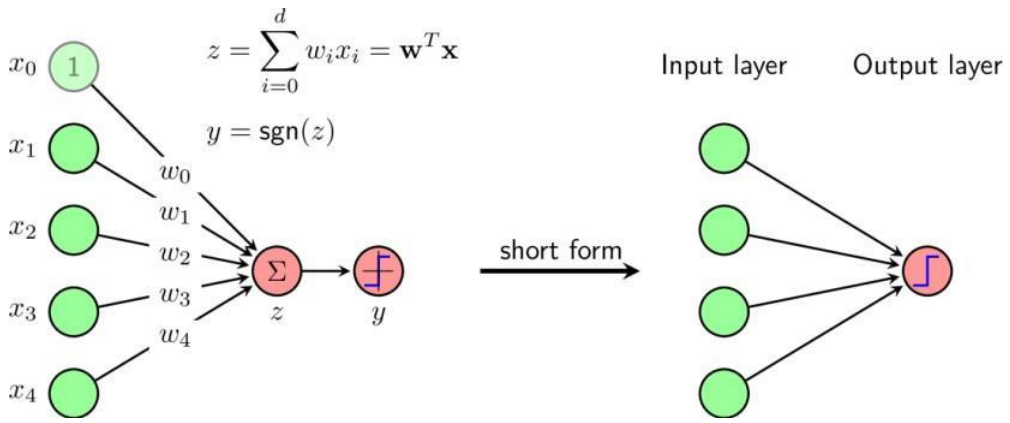

Hình 15. Hình ảnh minh họa cho hoạt động của các node trong mạng nơ-ron

Trong đó, hàm sgn(z) được hiểu là hàm kích hoạt (activation function).

2.4. Hàm kích hoạt (activation function)

Hàm kích hoạt là những hàm phi tuyến được áp dụng vào đầu ra của các nơ-ron trong tầng ẩn của một mô hình mạng, và được sử dụng làm input data cho tầng tiếp theo.

Trước tiên, ta cần hiểu lý do chính làm các mô hình mạng neural nổi bật hơn so với các mô hình học máy là khả năng giải quyết được những vấn đề về tính chất phi tuyến của dữ liệu (non-linear separable data). Những tầng mạng nằm giữa tầng đầu vào và đầu ra của một mạng nơ-ron được gọi là tầng ẩn. Những tầng ẩn này giữ nhiệm vụ giải quyết những quan hệ phi tuyến phức tạp giữa các đặc điểm của dữ liệu và kết quả đầu ra của mô hình nhờ những hàm "phi tuyến hóa" thường được biến đến với tên hàm kích hoạt.

Nếu chỉ áp dụng một hàm tuyến tính vào đầu ra của mỗi nơ-ron, sẽ dẫn đến việc mô hình mạng nơ-ron không khác gì mô hình học máy thông thường(điển hình là mô hình hồi quy tuyến tính). Vì phép biến đổi không có tính chất phi tuyến, việc này không khác gì chúng ta thêm một tầng ẩn nữa vì phép biến đổi cũng chỉ đơn thuần là nhân đầu ra với các trọng số. Với chỉ những phép tính đơn thuần như vậy, trên thực tế mạng nơ-ron sẽ không thể phát hiện ra những quan hệ phức tạp của dữ liệu (ví dụ như: dự đoán chứng khoán, các bài toán xử lý ảnh hay các bài toán phát hiện ngữ nghĩa của các câu trong văn bản). Nói cách khác nếu không có các hàm kích hoạt, khả năng dự đoán của mạng nơ-ron sẽ bị giới hạn và giảm đi rất nhiều, sự kết hợp của các hàm kích hoạt giữa các tầng ẩn là để giúp mô hình học được các quan hệ phi tuyến phức tạp tiềm ẩn trong dữ liệu.

Các hàm kích hoạt thường gặp:

a. Hàm sigmoid

- Công thức:

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

- Đồ thị hàm sigmoid:

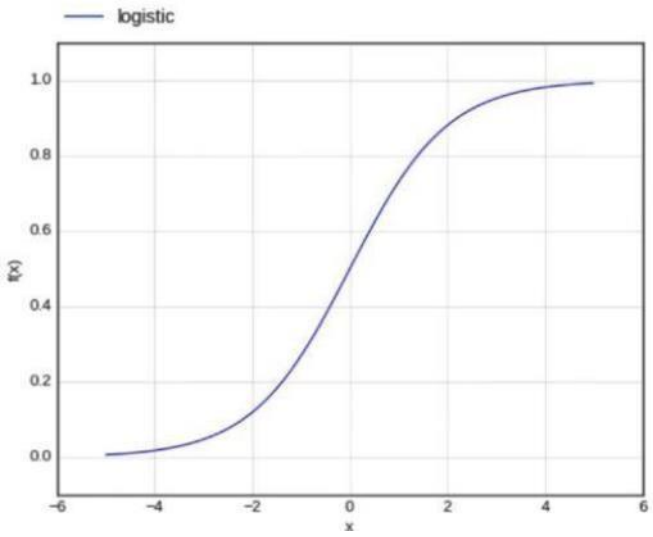

Hình 16. Đồ thị hàm Sigmoid

Hàm Sigmoid nhận đầu vào là một số thực và chuyển thành một giá trị trong khoảng (0;1) (xem đồ thị phía trên). Đầu vào là số thực âm rất nhỏ sẽ cho đầu ra tiệm cận với 0, ngược lại, nếu đầu vào là một số thực dương lớn sẽ cho đầu ra là một số tiệm cận với 1.

b. Hàm tanh

- Công thức:

$$\tanh(x) = \frac{e^{x} - e^{-x}}{e^{x} + e^{-x}}$$

- Đồ thị hàm tanh

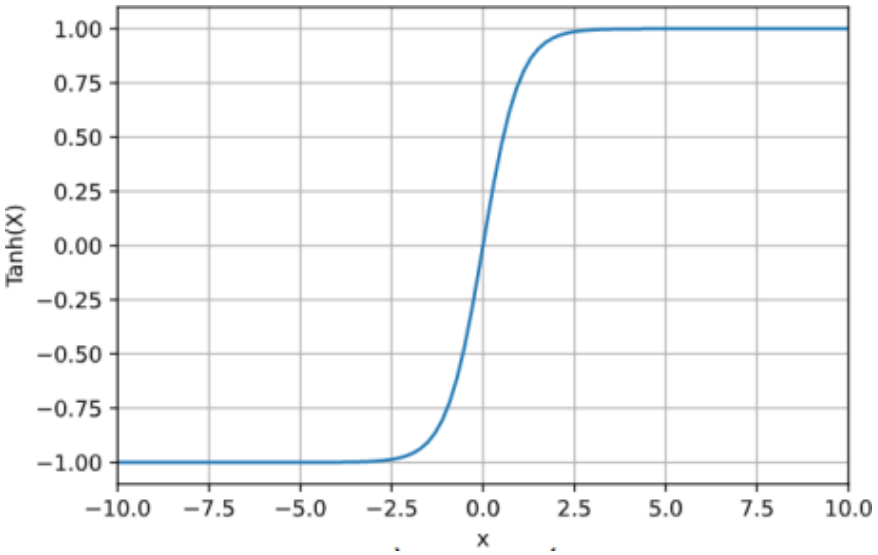

Hình 17. Đồ thị hàm Tanh

Hàm tanh nhận đầu vào là một số thực và chuyển thành một giá trị trong khoảng (-1; 1). Cũng như sigmoid, hàm tanh bị bão hoà ở 2 đầu (gradient thay đổi rất ít ở 2 đầu). Tuy nhiên hàm Tanh lại đối xứng qua 0 nên khắc phục được một nhược điểm của Sigmoid.

c. Hàm ReLU

- Công thức

$$f(x) = max(0, x)$$

- Đồ thị hàm ReLU

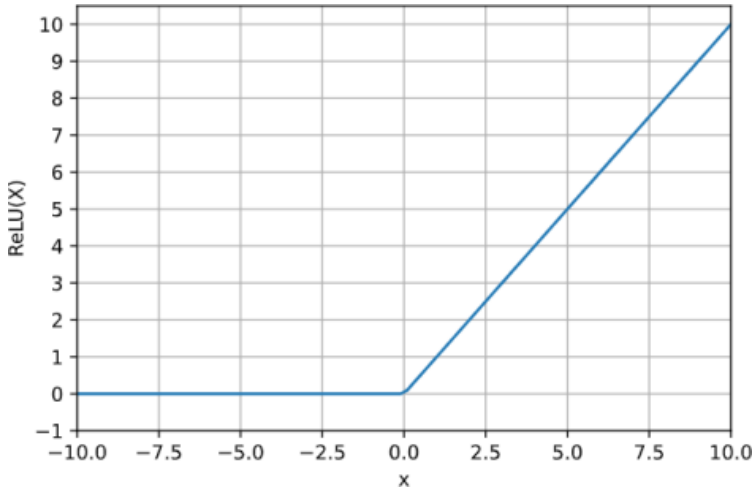

Hình 18. Đồ thị hàm ReLU

Hàm ReLU đang được sử dụng khá nhiều trong những năm gần đây khi huấn luyện các mạng neuron. ReLU đơn giản lọc các giá trị < 0. Nhìn vào công thức chúng ta dễ dàng hiểu được cách hoạt động của nó. Một số ưu điểm khá vượt trội của nó so với Sigmoid và Tanh.

3. K-Nearest-Neighbor

3.1. K-Nearest-Neighbor là gì?

K-Nearest-Neighbor (KNN) là một thuật toán học máy trong đó, để dự đoán nhãn của một mẫu mới, ta tìm kiếm K mẫu huấn luyện gần nhất của nó trong không gian đặc trưng, và dùng phương pháp bầu chọn đa số để quyết định nhãn của mẫu mới. KNN là một thuật toán phân loại phi tham số đơn giản và được sử dụng rộng rãi trong các bài toán phân loại và xử lý ảnh, như phân loại chữ số viết tay, nhận dạng khuôn mặt, phân loại email hoặc phân loại tin tức. Ngoài ra, KNN cũng có thể được sử dụng để giải quyết các bài toán hồi quy (regression) bằng cách sử dụng giá trị trung bình của K mẫu gần nhất để dự đoán giá trị đầu ra của mẫu mới.

Một cách ngắn gọn, KNN là thuật toán đi tìm đầu ra của một điểm dữ liệu mới bằng cách *chỉ* dựa trên thông tin của K điểm dữ liệu trong training set gần nó nhất (K-lân cận), *không quan tâm đến việc có một vài điểm dữ liệu trong những điểm gần nhất này là nhiễu*.

Vídụ:

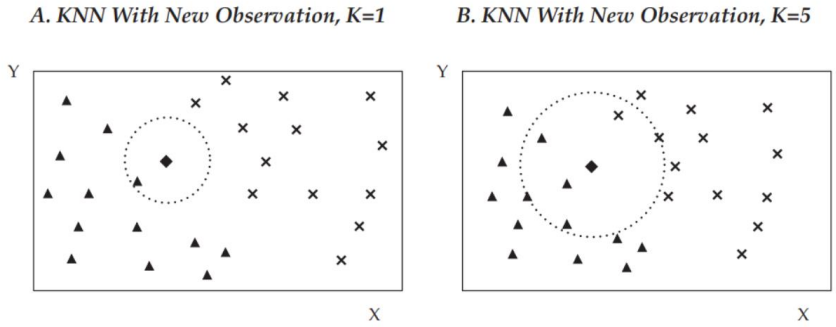

Hình 19. Ví dụ kNN

Hình thoi trong Hình 1 đang cần được phân loại thuộc hình chữ thập hoặc hình tam giác.

- Nếu k = 1, hình thoi sẽ được phân loại vào cùng loại với điểm dữ liệu gần nhất

của nó (tức là hình tam giác trong bảng bên trái - bảng A).

- Bảng bên phải (bảng B) thể hiện trường hợp k = 5, thuật toán sẽ xem xét 5 điểm dữ liệu gần hình thoi nhất, đó là 3 hình tam giác và 2 hình chữ thập. Qui tắc quyết định là chọn phân loại có số lượng lớn nhất trong 5 điểm dữ liệu được xem xét. Vì vậy, trong trường hợp này, hình thoi cũng được xếp vào phân loại tam giác.

3.2. Thí nghiệm để tìm tham số k tốt nhất

Chọn k trong tập sau: {3,5,7,9,11,15,19,25,31}

Xây dựng mô hình kNN đối với từng k trong tập tương ứng:

```
#Thử nghiệm để tìm tham số tốt nhất cho thuật toán k-nearest-neighbor
from sklearn.neighbors import KNeighborsClassifier
import numpy as np

# Mảng lưu kết quả thí nghiệm
val_acc = []
val_f1 = []
train_acc = []
train_f1 = []
# Mảng lưu các tham số k
arr = [3,5,7,9,11,15,19,25,31]

X_train, X_val, y_train, y_val = train_test_split(X_data_tfidf_svd, np.array(y_data_n), test_size=0.2, random_state=42)

for k in arr:
  knn = KNeighborsClassifier(n_neighbors=k)
  knn.fit(X_train, y_train)
  train_predictions = knn.predict(X_train)
  val_predictions = knn.predict(X_val)
  val_acc.append(accuracy_score(val_predictions, y_val))
  train_acc.append(accuracy_score(train_predictions, y_train))
  val_f1.append(f1_score(val_predictions, y_val, average='weighted'))
  train_f1.append(f1_score(train_predictions, y_train, average='weighted'))
```

```
# Biểu đồ minh họa đối với tập validation
plt.figure(figsize=(15,12))
plt.plot(arr, val_acc)
plt.plot(arr, val_f1)
plt.title('Accuracy and F1 score kNN validation')
plt.ylabel('')
plt.xlabel('k = ')
plt.legend(['accuracy', 'f1_score'], loc='upper right')
plt.show()
```

Hình 20. Source code tìm tham số k tốt nhất

Kết quả thử nghiệm như sau:

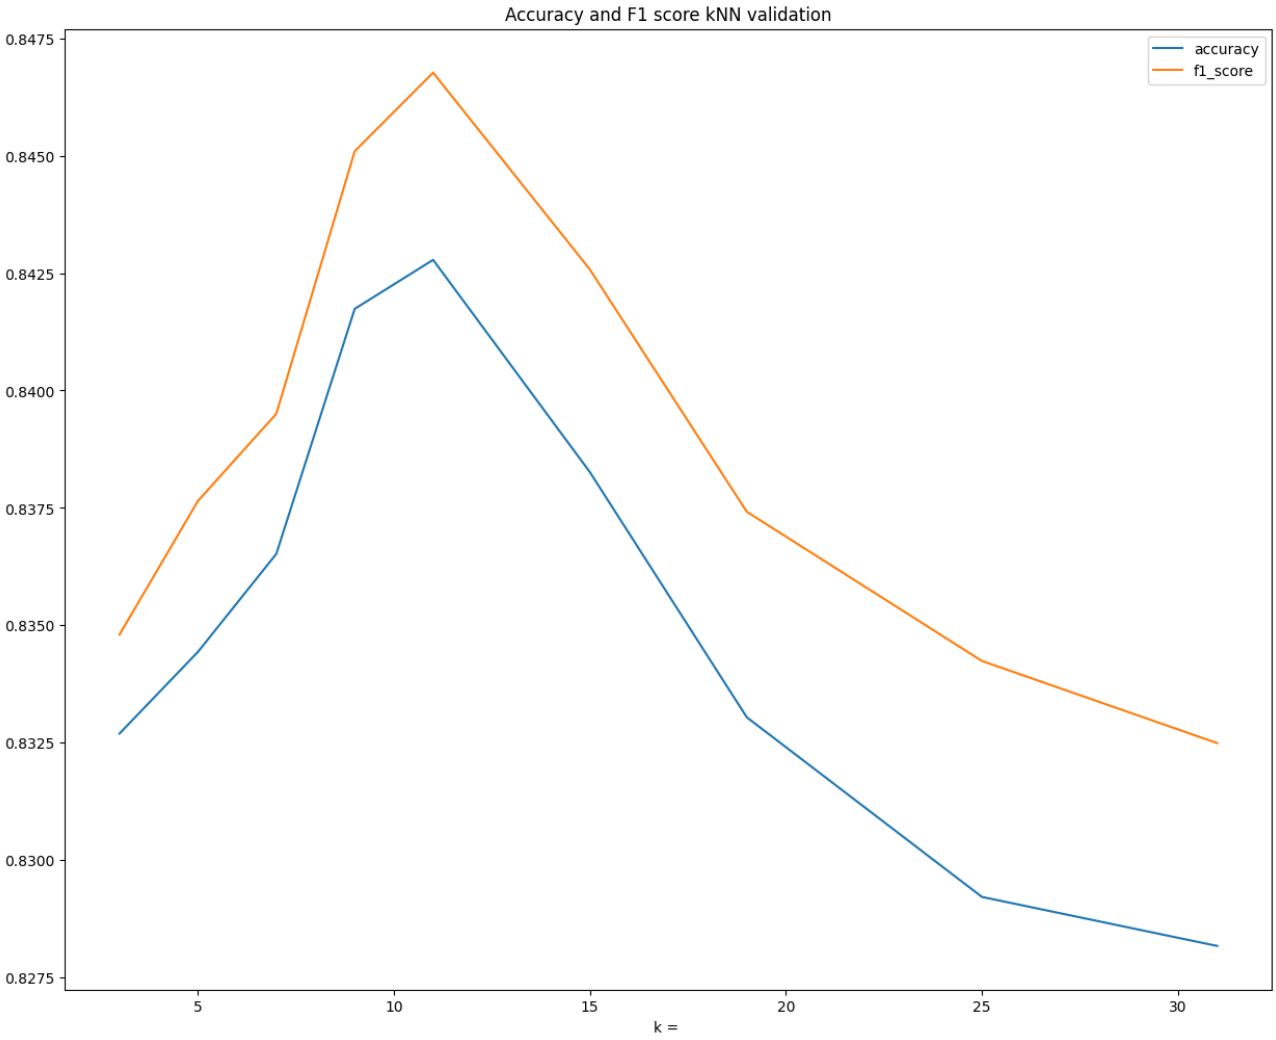

Hình 21. Kết quả thử nghiệm mô hình kNN

Như vậy, từ kết quả thử nghiệm, tham số k=11 được cho là tốt nhất cho mô hình.

3.3 Tiêu chí đánh giá

Có thể sử dụng các tiêu chí sau để đánh giá mô hình KNN:

- Accuracy: Đây là tiêu chí đánh giá độ chính xác của mô hình. Accuracy được tính bằng tỷ lệ số lượng mẫu được phân loại đúng trên tổng số lượng mẫu.
- Precision và Recall: Precision là tỷ lệ số lượng mẫu được phân loại đúng của một lớp trên tổng số lượng mẫu được phân loại vào lớp đó. Recall là tỷ lệ số lượng mẫu được phân loại đúng của một lớp trên tổng số lượng

mẫu thuộc lớp đó. Precision và recall được sử dụng khi các lớp trong bài toán không cân bằng về số lượng mẫu.

- F1 score: F1 score là trung bình điều hòa giữa precision và recall. F1 score càng cao thì mô hình càng tốt.
- Confusion matrix: Confusion matrix là ma trận thể hiện số lượng mẫu được phân loại đúng và sai trong từng lớp. Confusion matrix cung cấp cho chúng ta một cái nhìn chi tiết về hiệu suất của mô hình và giúp chúng ta đánh giá được các lỗi phân loại.

Vì dữ liệu trong mô hình trên phân bố không đồng đều, nên việc sử dụng accuracy để đánh giá có thể đưa ra những kết quả không chính xác. Ví dụ với bài toán phân loại 2 nhãn (binary classification) nhưng nhãn thứ nhất có kích thước áp đảo là 99% bộ dữ liệu trong khi nhãn thứ hai chỉ chiếm 1% tập dữ liệu. Nếu mô hình dự đoán toàn bộ các điểm dữ liệu là thuộc nhãn số một thì nó đã đạt được 99% độ chính xác trong khi thực chất nó không hề học được gì và dự đoán sai hết những phần tử thuộc nhãn thứ hai. Vì vậy, việc sử dụng accuracy trong trường hợp này có thể không hiệu quả và không công bằng giữa các nhãn.

$$\frac{2}{F1} = \frac{1}{precision} + \frac{1}{recall}$$

Với độ đo f1 thì lại khác, f1 là trung bình điều hòa giữa precision và recall, tức là nó sẽ gần hơn với giá trị nhỏ hơn trong 2 giá trị trên. Với đặc điểm này, việc đánh giá sử dụng độ đo f1 sẽ cho kết quả chính xác hơn. Giả sử trong tình huống trên, nếu sử dụng f1 score, nó sẽ cho điểm rất thấp. Điều này sẽ buộc mô hình phải cố gắng phân loại cả hai nhãn thay vì thiên vị hoàn toàn cho nhãn có số lượng áp đảo hơn.

4. Hồi quy tuyến tính

4.1 Giới thiệu

Linear Regression (Hồi quy tuyến tính) là một trong những thuật toán cơ bản và phổ biến nhất của Supervised Learning (Học có giám sát), trong đó đầu ra dự đoán là liên tục.

4.2 Lý thuyết toán học

Giả sử ta có phân bố ở một mặt phẳng dưới dạng một đường thẳng, nhiệm vụ của chúng ta là tìm ra phương trình đường thẳng khớp nhất với dữ liệu đó. Phương trình đường thẳng cho bài toán này khá đơn giản, hầu hết chúng ta đã quen thuộc với nó từ trung học:

$$y = ax + b$$

trong đó a có thể được coi là độ dốc hay slope, quyết định đến độ nghiêng của đường thẳng; còn b có thể hiểu là chặn hay intercept của đường thẳng, quyết định sự dịch chuyển của đường thẳng so với gốc toạ độ. Với b=0, đường thẳng sẽ đi qua gốc toạ độ.

Hãy xem xét một dữ liệu có dạng đường thẳng với a=3 và b=−5 (là đường thẳng màu đỏ trong hình bên dưới). Ở đây tôi sẽ dùng np.random để tạo ra các điểm phân bố theo một đường thẳng (các chấm xanh ở trong hình vẽ). Ở phần sau của bài viết này, ta sẽ cùng tìm hiểu cách dùng Linear Regression để tìm phương trình đường thẳng ứng với các điểm dữ liệu rời rạc đó.

```
rng = np.random.RandomState(1)
x = 10 * rng.rand(25)
y = 3 * x - 5 + rng.randn(25)
plt.scatter(x, y)
plt.plot(x, 3 * x - 5, linestyle='solid', color='red')
```

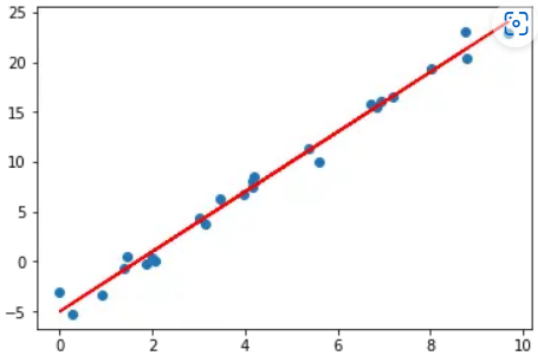

Hình 22. Ví dụ hồi quy tuyến tính

Tìm phương trình đường thẳng là một trường hợp hết sức đơn giản của có thể áp dụng Linear Regression. Trên thực tế, dữ liệu của bài toán Linear Regression có thể nằm trong không gian nhiều hơn 2 chiều. Khi đó, ta có thể hiểu một cách trực quan là output $\hat{y}$ của bài toán chính là sự kết hợp các input x_i theo một tỷ lệ nào đó. Tỷ lệ này là các hệ số w_i, và thường được gọi là trọng số của mô hình. Các giá trị x_i có thể được viết thành vector $\mathbf{X}$, các trọng số w_i có thể được viết thành vector $\mathbf{W}$. Việc tối ưu mô hình Linear Regression là tìm ra vector $\mathbf{W}$ sao cho từ input $\mathbf{X}$ ta có thể tính ra được output $\hat{y}$ của bài toán.

Hãy cùng xem xét biểu diễn bài toán trong không gian n chiều. Ví dụ bài toán xác định gía nhà dựa trên n thuộc tính của căn nhà như diện tích, số phòng, khoảng cách đến trung tâm thành phố... Khi đó input của bài toán sẽ là vector $\mathbf{X} = [x_1, x_2, x_3, \ldots, x_n]$ thể hiện các thuộc tính của căn nhà dưới dạng các số thực và output sẽ là $\hat{y} = f(\mathbf{X}) \approx y$, với y là giá trị thật của căn nhà. $f(\mathbf{X})$ có thể được tính bằng công thức sau:

$$f(\mathbf{X}) = w_0 + w_1 x_1 + w_2 x_2 + w_3 x_3 + \cdots + w_n x_n$$

Nhìn chung giá trị dự đoán $\hat{y}$ và giá trị thật y thường là 2 giá trị khác nhau do sai số mô hình. Nhiệm vụ của bài toán này là đi tìm các tham số tối ưu $\{w_0, w_1, w_2, w_3, \ldots, w_n\}$ sao cho sự khác nhau này là nhỏ nhất. Bài toán xác định phương trình đường thẳng trong mục 1 chính là trường hợp $n = 2$, w_1 là a và w_0 là b.

Ta có thể biểu diễn tham số dưới dạng một vector cột $\mathbf{W} = [w_0, w_1, w_2, w_3, \ldots, w_n]^T$ và input $\mathbf{X}$ mở rộng dưới dạng $\bar{\mathbf{X}} = [1, x_1, x_2, x_3, \ldots, x_n]$. Ở đây, ta thêm số 1 vào $\bar{\mathbf{X}}$ để không cần phải xử lý riêng một trường hợp tham số tự do w_0.

Việc tính toán giá trị output dự đoán trở thành:

$$\hat{y} = \bar{\mathbf{X}}\mathbf{W}$$

Sai số dự đoán $e = y - \hat{y}$ được gọi là sai số dự đoán. Giá trị này sẽ được tối ưu sao cho gần 0 nhất.

Chúng ta cần ước lượng xem mô hình của chúng ta bị sai, bị lỗi đến đâu, để từ đó tối ưu mô hình để có thể hoạt động ít lỗi nhất. Việc tính lỗi này không thể dựa vào cảm tính, mà phải dựa vào tính toán số học. Đó là lý do định nghĩa hàm mất mát (loss function) ra đời. Ta có thể hiểu hàm này được thiết kế để đánh giá độ lỗi, độ sai của mô hình. Kết quả của hàm này có giá trị càng lớn thì mô hình của chúng ta càng sai. Việc tối ưu bài toán được đưa về việc tối ưu các giá trị trọng số để hàm mất mát có giá trị nhỏ nhất.

Ở bài toán này, dữ liệu huấn luyện gồm n mẫu - n cặp giá trị $(\mathbf{X}\_i, y_i)$ với $i = 1, 2, \ldots, n$. Hàm mất mát có thể được định nghĩa là:

$$\mathcal{L}(\mathbf{W}) = \frac{1}{2}\sum_{i=1}^{n}(y_i - \bar{\mathbf{X}}_\mathbf{i}\mathbf{W})^2 = \frac{1}{2}\|\mathbf{y} - \bar{\mathbf{X}}\mathbf{W}\|_2^2$$

Ở công thức trên, chúng ta lấy giá trị output thực tế ở trong tập dữ liệu huấn luyện $\mathbf{y}$ trừ đi giá trị dự đoán $\hat{y} = \bar{\mathbf{X}}\mathbf{w}$ sau đó lấy bình phương của kết quả đó để ước lượng sai số của 1 điểm dữ liệu. Tại sao không phải lấy trị tuyệt đối, vì chỉ cần lấy giá trị tuyệt đối là ta đã có thể có một dạng sai số rồi? Câu trả lời là do chúng ta cần một hàm để dễ tính toán đạo hàm ở bước tìm nghiệm cho bài toán. Hàm bình phương có đạo hàm tại mọi điểm, còn trị tuyệt đối có đạo hàm bị đứt tại điểm 0. Số $\frac{1}{2}$ trong công thức trên chỉ có ý nghĩa làm đẹp kết quả của đạo hàm.

Giá trị tối ưu của w được ký hiệu là:

$$\mathbf{w}^* = \arg\min_{\mathbf{w}} \mathcal{L}(\mathbf{w})$$

Để tìm nghiệm cho bài toán Linear Regression, chúng ta có thể giải phương trình đạo hàm của hàm loss bằng 0. Đạo hàm theo w của hàm loss có dạng:

$$\frac{\partial \mathcal{L}(\mathbf{w})}{\partial \mathbf{w}} = \bar{\mathbf{X}}^T(\bar{\mathbf{X}}\mathbf{w} - \mathbf{y})$$

Nghiệm tối ưu cho bài toán này có dạng như sau

$$\mathbf{w} = (\bar{\mathbf{X}}^T\bar{\mathbf{X}})^\dagger\bar{\mathbf{X}}^T\mathbf{y}$$

5. Support Vector Machines

SVM là một thuật toán giám sát, nó có thể sử dụng cho cả việc phân loại hoặc đệ quy. Tuy nhiên nó được sử dụng chủ yếu cho việc phân loại. Trong thuật toán này, chúng ta vẽ đồi thị dữ liệu là các điểm trong n chiều (ở đây n là số lượng các tính năng bạn có) với giá trị của mỗi tính năng sẽ là một phần liên kết. Sau đó chúng ta thực hiện tìm "đường bay" (hyper-plane) phân chia các lớp. Hyper-plane nó chỉ hiểu đơn giản là 1 đường thẳng có thể phân chia các lớp ra thành hai phần riêng biệt.

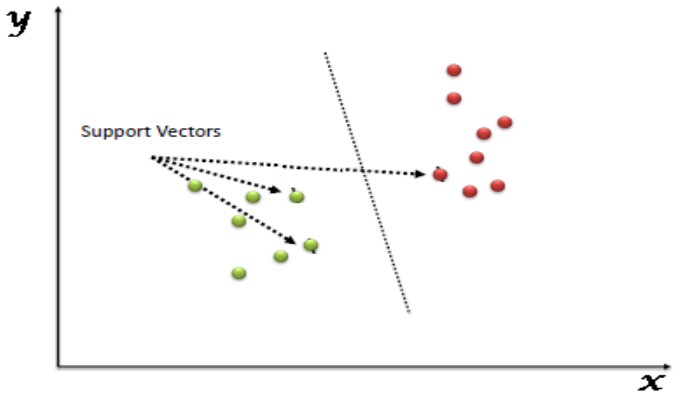

Hình 23. Mô tả Support Vectors

Support Vectors hiểu một cách đơn giản là các đối tượng trên đồ thị tọa độ quan sát, Support Vector Machine là một biên giới để chia hai lớp tốt nhất.

D. Kết quả mô hình

Xây dựng hàm huấn luyện dùng chung cho vài mô hình

```
def train_model(classifier, new_X_data, y_data, new_X_test, y_test, is_neuralnet=False):
    X_train, X_val, y_train, y_val = train_test_split(new_X_data, y_data, test_size=0.1, random_state=42)

    if is_neuralnet:
        classifier.fit(X_train, y_train, validation_data=(X_val, y_val), epochs=30, batch_size=512)

        val_predictions = classifier.predict(X_val)
        test_predictions = classifier.predict(new_X_test)
        val_predictions = val_predictions.argmax(axis=-1)
        test_predictions = test_predictions.argmax(axis=-1)
    else:
        classifier.fit(X_train, y_train)

        train_predictions = classifier.predict(X_train)
        val_predictions = classifier.predict(X_val)
        test_predictions = classifier.predict(new_X_test)

    print("Validation accuracy: ", metrics.accuracy_score(val_predictions, y_val))
    print("Test accuracy: ", metrics.accuracy_score(test_predictions, y_test))
```

Hình 24. Hàm huấn luyện

I. Multinomial Naive Bayes

Xét tập alphas = [0.000001, 0.00001, 0.0001, 0.01, 0.1, 0.5, 1.0, 2.0, 10.0]

Thử nghiệm mô hình với từng alpha, ta thu được kết quả sau đây

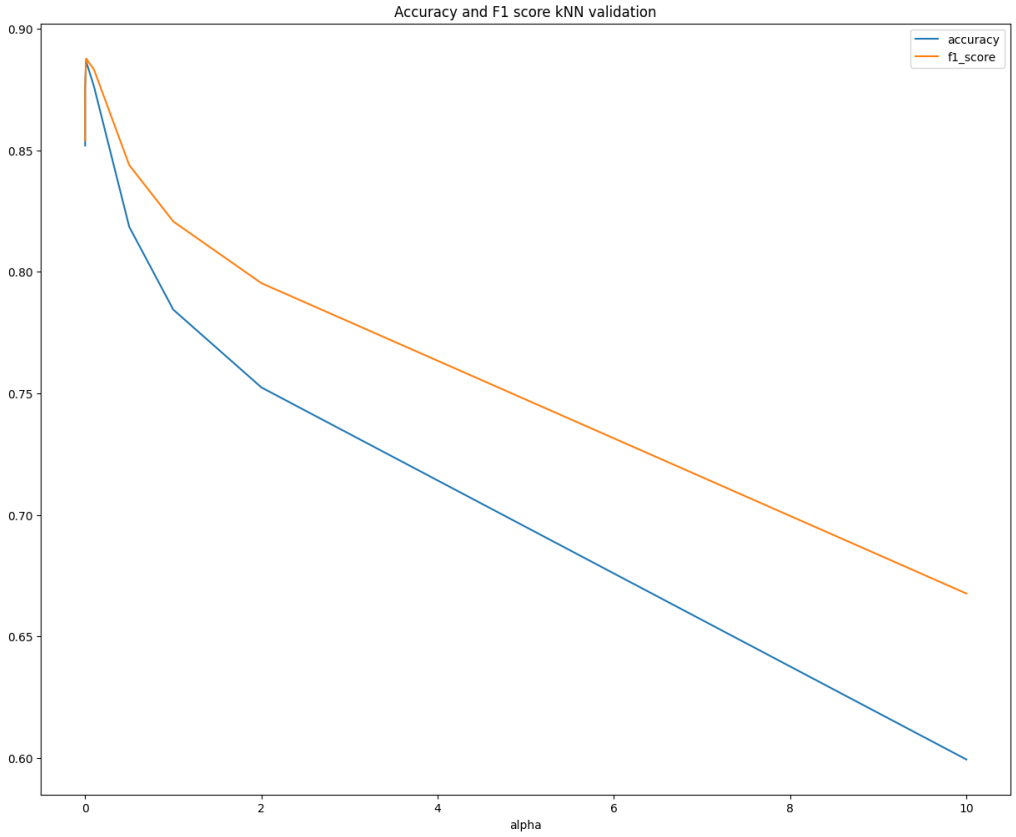

Hình 25. Kết quả thu được với mô hình Naive Bayes trên tập validation

Như vậy, em nhận thấy tham số α = 0.01 là tốt nhất đối với bộ dữ liệu Tiến hành chạy thử mô hình Multinomial Naive Bayes cho ra kết quả sau đây:

- Với α = 0.01 (alpha = 0.01):

  Validation accuracy: 0.8866481223922114

  Test accuracy: 0.8916859887379928

```
[ ]  # Train với Naive Bayes
     X_train, X_val, y_train, y_val = model_selection.train_test_split(X_data_tfidf, y_data, test_size=0.1, random_state=42)
     model=nb.MultinomialNB(alpha=0.01, fit_prior=True)

     model.fit(X_train, y_train)

     val_predictions = model.predict(X_val)
     test_predictions = model.predict(X_test_tfidf)

     print("Validation accuracy: ", sklearn.metrics.accuracy_score(val_predictions, y_val))
     print("Test accuracy: ", sklearn.metrics.accuracy_score(test_predictions, y_test))
```

```
Validation accuracy:  0.8866481223922114
Test accuracy:  0.8916859887379928
```

Hình 26. Kết quả thử nghiệm mô hình Multinomial Naive Bayes

II. Deep Neural Network (DNN)

Tiến hành chạy thử mô hình Deep Neural Network cho ra kết quả sau đây

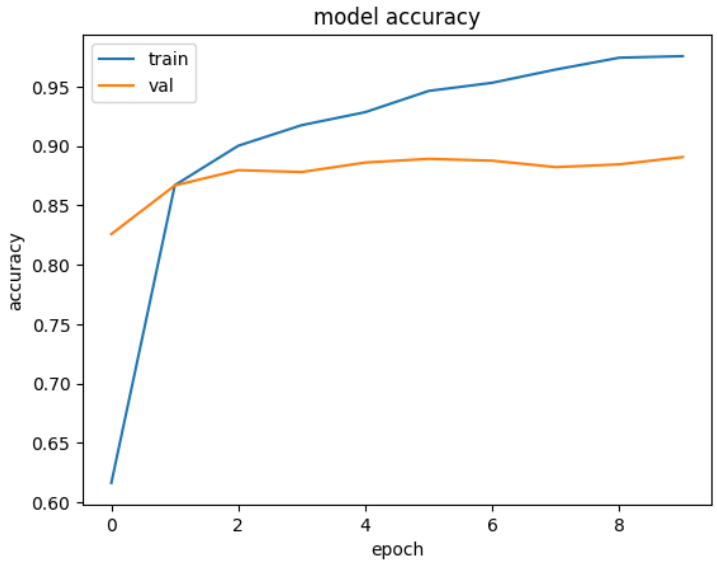

Hình 27. Đồ thị accuracy theo từng epoch

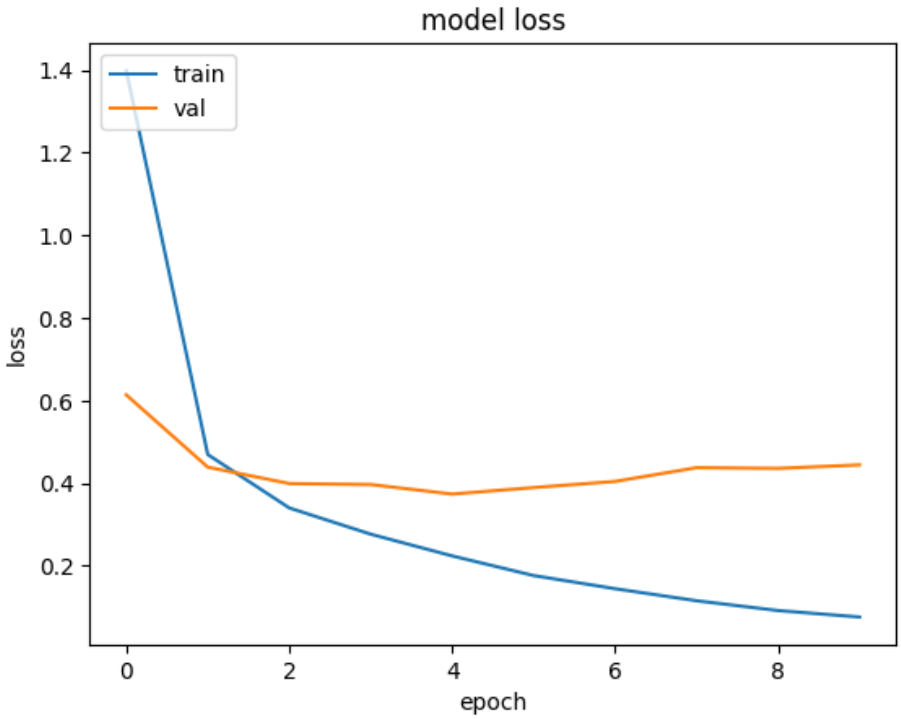

Hình 28. Đồ thị loss theo từng epoch

Các chỉ số đánh giá cho mô hình mạng nơ ron:

```
45/45 [==============================] - 0s 5ms/step - loss: 0.5573 - accuracy: 0.8665
378/378 [==============================] - 2s 5ms/step - loss: 0.4896 - accuracy: 0.8752
[0.48961007595062256, 0.8752070069313049]
```

Hình 29. Các chỉ số đánh giá cho mô hình mạng nơ ron

III. Long short term memory (LSTM)

```
classifier = create_lstm_model()
train_model(classifier=classifier, new_X_data=X_data_tfidf_svd, y_data=y_data_n,
new_X_test=X_test_tfidf_svd, y_test=y_test_n, is_neuralnet=True)
```

```
Epoch 29/30
26/26 [==============================] - 3s 132ms/step - loss: 0.8064 - accuracy: 0.7426 - val_loss: 0.9931 - val_accuracy: 0.6878
Epoch 30/30
26/26 [==============================] - 4s 147ms/step - loss: 0.7890 - accuracy: 0.7492 - val_loss: 0.9217 - val_accuracy: 0.7232
45/45 [==============================] - 1s 8ms/step
378/378 [==============================] - 3s 8ms/step
Validation accuracy:  0.7232267037552156
Test accuracy:  0.7093408413381914
```

Hình 30. Ví dụ mô hình LSTM

IV. Gated recurrent unit (GRU)

```
classifier = create_gru_model()
train_model(classifier=classifier, new_X_data=X_data_tfidf_svd, y_data=y_data_n,
new_X_test=X_test_tfidf_svd, y_test=y_test_n, is_neuralnet=True)
```

```
Epoch 29/30
26/26 [==============================] - 2s 88ms/step - loss: 1.0555 - accuracy: 0.6574 - val_loss: 1.2110 - val_accuracy: 0.6231
Epoch 30/30
26/26 [==============================] - 2s 87ms/step - loss: 1.0341 - accuracy: 0.6683 - val_loss: 1.0925 - val_accuracy: 0.6599
45/45 [==============================] - 0s 6ms/step
378/378 [==============================] - 2s 5ms/step
Validation accuracy:  0.6599443671766342
Test accuracy:  0.63696588274263
```

Hình 31. Ví dụ mô hình GRU

V. Bidirectional recurrent neural networks (BRNN)

```
classifier = create_brnn_model()
train_model(classifier=classifier, new_X_data=X_data_tfidf_svd, y_data=y_data_n,
new_X_test=X_test_tfidf_svd, y_test=y_test_n, is_neuralnet=True)
```

```
Epoch 29/30
26/26 [==============================] - 4s 142ms/step - loss: 0.2748 - accuracy: 0.9112 - val_loss: 0.4109 - val_accuracy: 0.8748
Epoch 30/30
26/26 [==============================] - 5s 199ms/step - loss: 0.2762 - accuracy: 0.9099 - val_loss: 0.4291 - val_accuracy: 0.8588
45/45 [==============================] - 1s 10ms/step
378/378 [==============================] - 4s 11ms/step
Validation accuracy:  0.8588317107093185
Test accuracy:  0.8748757866843325
```

Hình 32. Ví dụ mô hình BRNN

VI. R-CNN

```
classifier = create_rcnn_model()
train_model(classifier=classifier, new_X_data=X_data_tfidf_svd, y_data=y_data_n,
new_X_test=X_test_tfidf_svd, y_test=y_test_n, is_neuralnet=True)
```

```
Epoch 29/30
26/26 [==============================] - 6s 216ms/step - loss: 0.1944 - accuracy: 0.9368 - val_loss: 0.4191 - val_accuracy: 0.8811
Epoch 30/30
26/26 [==============================] - 7s 269ms/step - loss: 0.1909 - accuracy: 0.9380 - val_loss: 0.4345 - val_accuracy: 0.8727
45/45 [==============================] - 1s 10ms/step
378/378 [==============================] - 4s 10ms/step
Validation accuracy:  0.872739916550765
Test accuracy:  0.8711493872143093
```

Hình 33. Ví dụ mô hình R-CNN

VII. K-Nearest-Neighbor

Tiến hành thử nghiệm với mô hình kNN, tham số k=11

```
[ ]  knn = KNeighborsClassifier(n_neighbors=11)
     knn.fit(X_train, y_train)

     val_predictions = knn.predict(X_val)
     val_acc = accuracy_score(val_predictions, y_val)
     val_f1 = f1_score(val_predictions, y_val, average='weighted')

     print("Validation accuracy:", val_acc)
     print("Validation F1 score:", val_f1)
```

```
Validation accuracy: 0.8427826086956521
Validation F1 score: 0.8467687490483039
```

Hình 34. Kết quả thu được đối với mô hình kNN

VIII. Linear Classifier

```
train_model(LogisticRegression(), X_data_tfidf_svd, y_data, X_test_tfidf_svd, y_test, is_neuralnet=False)
```

```
Validation accuracy:  0.8824756606397774
Test accuracy:  0.8867174561112952
```

Hình 35. Ví dụ mô hình Linear Classifier

IX. Support Vector Machine (SVM)

```
train_model(svm.SVC(), X_data_tfidf_svd, y_data, X_test_tfidf_svd, y_test, is_neuralnet=False)
```

```
Validation accuracy:  0.8963838664812239
Test accuracy:  0.9045213646902948
```

Hình 36. Ví dụ mô hình SVM

X. Bagging Model

```
train_model(RandomForestClassifier(), X_data_tfidf_svd, y_data, X_test_tfidf_svd, y_test, is_neuralnet=False)
```

```
Validation accuracy:  0.8692628650904033
Test accuracy:  0.8714806227227558
```

Hình 37. Ví dụ mô hình Bagging Model

XI. Confusion matrix

Như vậy, sau khi tiến hành thử nghiệm, mô hình tốt nhất mà đề xuất là mô hình SVM với kết quả

```
train_model(svm.SVC(), X_data_tfidf_svd, y_data, X_test_tfidf_svd, y_test, is_neuralnet=False)
```

```
Validation accuracy:  0.8963838664812239
Test accuracy:  0.9045213646902948
```

Hình 38. Kết quả thu được đối với mô hình SVM

Vẽ ma trận nhầm lẫn giúp quan sát kết quả của bài toán:

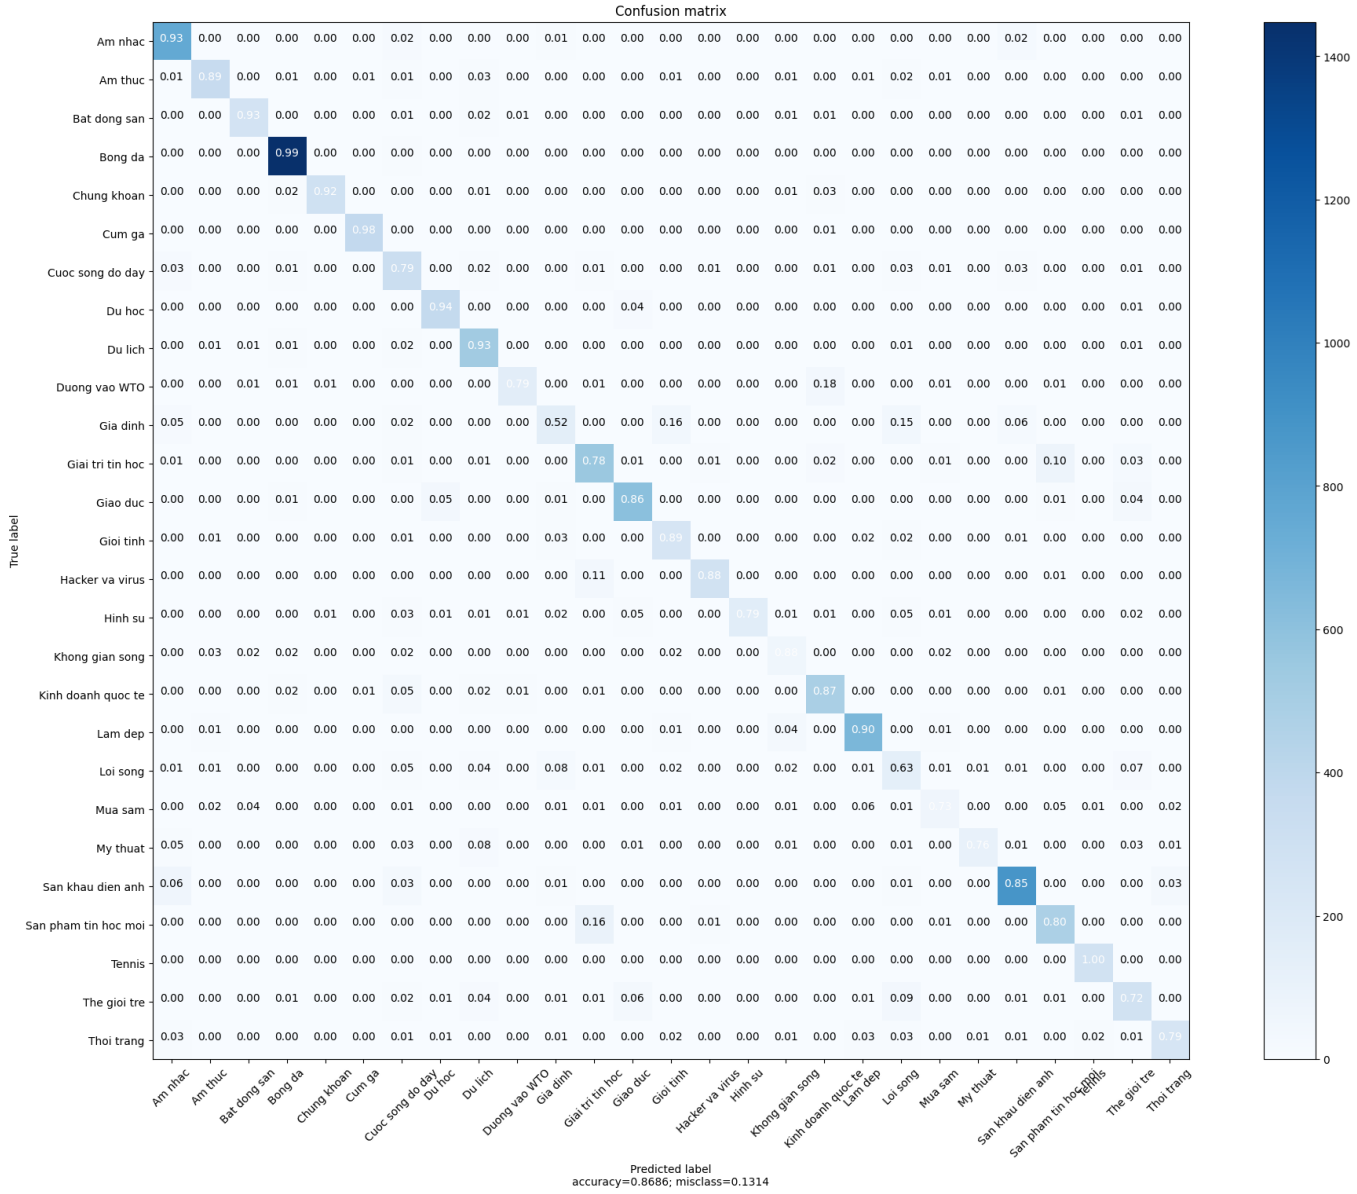

Hình 39. Ma trận nhầm lẫn của mô hình

E. Kết luận và cải tiến

Qua quá trình thử nghiệm và đánh giá, đã đạt được một số kết quả nhất định.

Theo đó, mô hình SVM là mô hình cho được kết quả tốt nhất. Tuy nhiên, theo như confusion matrix (ma trận nhầm lẫn), một số chủ đề giống nhau vẫn đang bị phân loại sai. Điển hình như nhãn "Sản phẩm tin học" với "Giải trí tin học". Nhìn chung, các chủ đề này cũng khá khó để phân biệt. Ngoài ra, các nhãn như "Lối sống", "Gia đình", "Mua sắm" đang có độ chính xác thấp. Theo đó, trong quá trình cải tiến sau này, em dự định sẽ cải tiến mô hình để dự đoán các nhãn này chính xác hơn. Mô

hình cần được tối ưu hơn phần tiền xử lý văn bản và trích chọn đặc trưng vì có vẻ như các chủ đề trên không có các từ khóa chủ đạo (dễ bị nhầm lẫn sang chủ đề khác), nên phương pháp tf-idf không thực sự hữu dụng, hoặc mô hình cần được cải tiến bằng các thuật toán khác của học sâu.

Danh mục tài liệu tham khảo

1. Bài viết *Singular Value Decomposition* trên blog https://machinelearningcoban.com/.
2. Bài viết *Naive Bayes Classifier* trên blog https://machinelearningcoban.com/.
3. Bài viết *Phân loại văn bản tiếng Việt sử dụng machine learning* trên blog https://blog.luyencode.net.
4. Bài viết *Phân loại văn bản tự động bằng machine learning như thế nào.* Phát hành ngày 11/10/2018, Trên website https://viblo.asia/.
5. Đồ án tốt nghiệp *Phân loại từ tiếng việt sử dụng mô hình CRFs* của tác giả Nguyễn Trung Kiên – trường đại học Công Nghệ ĐHQGHN.
6. Bài viết *Tokenization là gì? Các kỹ thuật tách từ trong xử lý ngôn ngữ tự nhiên.* Phát hành ngày 18/08/2021, đăng trên website https://vinbigdata.com/
7. Bài viết *Tổng quan về thuật toán phân lớp Naive Bayes Classification (NBC).* Phát hành ngày 21/07/2018, từ http://hoctructuyen123.net/tong-quan-ve-thuat-toan-phan-lop-naive-bayes-classification-nbc/
8. Bài viết *Phân loại văn bản tự động bằng Machine Learning như thế nào?* của tác giả Nguyễn Thành Hậu. Phát hành ngày 11/10/2018, từ https://viblo.asia/p/phan-loai-van-ban-tu-dong-bang-machine-learning-nhu-the-nao-4P856Pa1ZY3
9. Bài viết *Phân loại văn bản tự động bằng Machine Learning như thế nào? (Phần 2)* của tác giả Nguyễn Thành Hậu. Phát hành ngày 09/11/2018, từ https://viblo.asia/p/phan-loai-van-ban-tu-dong-bang-machine-learning-nhu-the-nao-phan-2-4P856PqBZY3
10. Bài giảng Convolutional Neural Network. (2019). Phát hành tháng 07/2020, từ https://nttuan8.com/bai-6-convolutional-neural-network/
11. Charu C. Aggarwal. (2018). Neural Networks and Deep Learning: A Textbook, first Edition
12. Đồ thị các hàm kích hoạt phổ biến. (2019). Phát hành tháng 09/2019, từ https://vietanh.dev/blog/2019-09-23-cac-ham-kich-hoat-activation-function-trong-neural-networks